Apprentissage Automatique

Introduction

Stéphane Herbin

stephane.herbin@onera.fr

ONERA
THE FRENCH AEROSPACE LAB

« Machine Learning »

- Un domaine scientifique hybride:
  - Statistique
  - Intelligence artificielle
  - « Computer science »

- Utilisant des techniques généralistes:
  - Optimisation numérique
  - Hardware
  - Gestion de base de données

ONERA
THE FRENCH AEROSPACE LAB

Pourquoi le « Machine Learning »?

- Thème à la mode: Intelligence Artificielle, « deep learning », « big data »…
- Raison épistémologique
  - On ne sait pas modéliser les problèmes complexes

  … mais on dispose d'exemples en grand nombre représentant la variété des situations
  - « Data driven » vs. « Model Based »
- Raison scientifique
  - L'apprentissage est une faculté essentielle du vivant
- Raison économique
  - La récolte de données est plus facile que le développement d'expertise

ONERA
THE FRENCH AEROSPACE LAB

Apprentissage automatique : applications

Anti-Spam (*Classifieur Bayesien*)



1997 : DeepBlue bat Kasparov (pas de ML)
2017: Alpha GO bat Ke Jie
2019: AlphaStar champion sur StarCraft



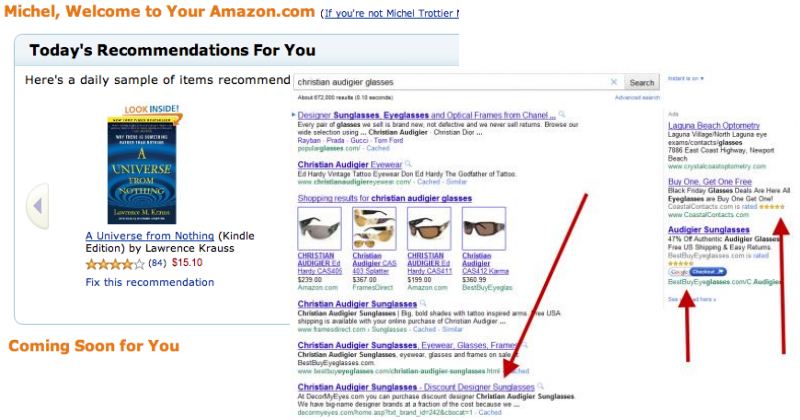
Tri postal automatique (*détection de chiffres manuscrits par réseaux de neurones*)



ONERA
THE FRENCH AEROSPACE LAB

Apprentissage automatique : applications

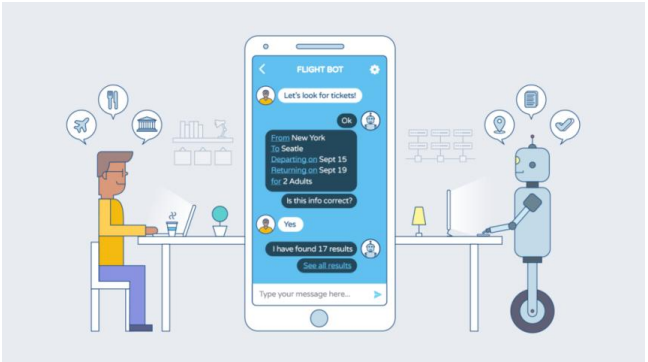
Recommandation ciblée
(*régression logistique*)



Appareil photo avec détection
de visages (*boosting*)



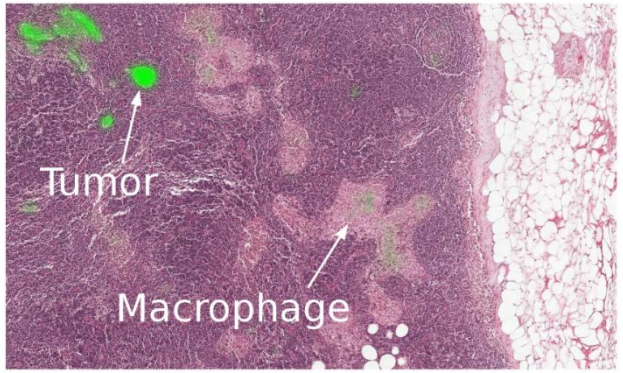
Chat Bots
(*Réseaux de neurones*)



ONERA
THE FRENCH AEROSPACE LAB

Apprentissage automatique : applications

Diagnostic médical
(*Réseaux de neurones profonds*)



Traduction multi-lingue
(Réseaux de neurones profonds)

Google Translate

DeepL

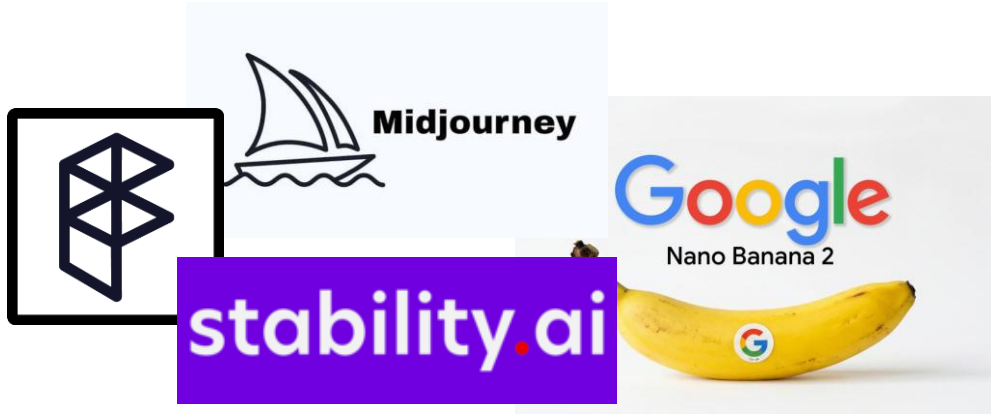
Biochimie (prédiction de la structure 3D des protéines)
(Réseaux de neurones profonds + modèles biologiques)



ONERA
THE FRENCH AEROSPACE LAB

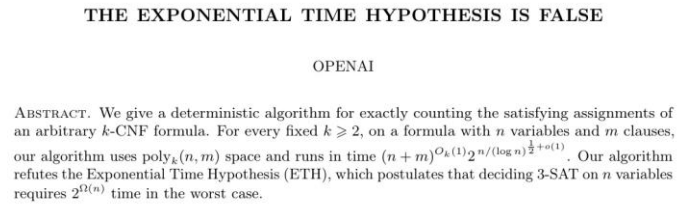
Apprentissage automatique : applications

Génération d'image ou vidéo
(Réseau de neurones profonds génératifs)



Démonstration mathématique
(« Agent IA »)





THE EXPONENTIAL TIME HYPOTHESIS IS FALSE

OPENAI

ABSTRACT. We give a deterministic algorithm for exactly counting the satisfying assignments of an arbitrary k-CNF formula. For every fixed $k \geqslant 2$, on a formula with n variables and m clauses, our algorithm uses $\mathrm{poly}_k(n,m)$ space and runs in time $(n+m)^{O_k(1)} 2^{n/(\log n)^{\frac{1}{2}+o(1)}}$. Our algorithm refutes the Exponential Time Hypothesis (ETH), which postulates that deciding 3-SAT on n variables requires $2^{\Omega(n)}$ time in the worst case.

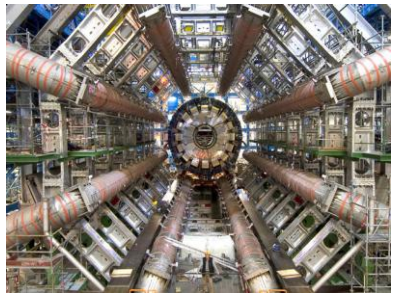
Codage informatique
(« Agent IA »)



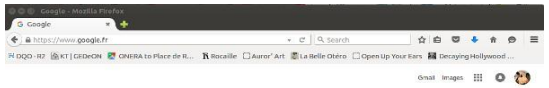
ONERA
THE FRENCH AEROSPACE LAB

Données = carburant du ML

CERN /
Large Hadron Collider
~70 Po/an



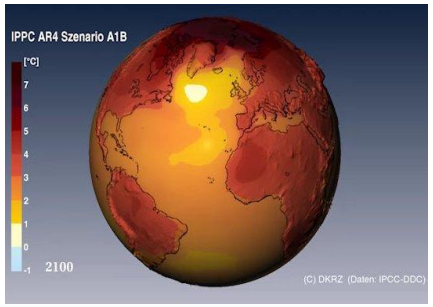
Google & consorts :
24 PetaOctets/jour



Copernicus :
> 1Po/an



DKRZ (Climat)
500 Po





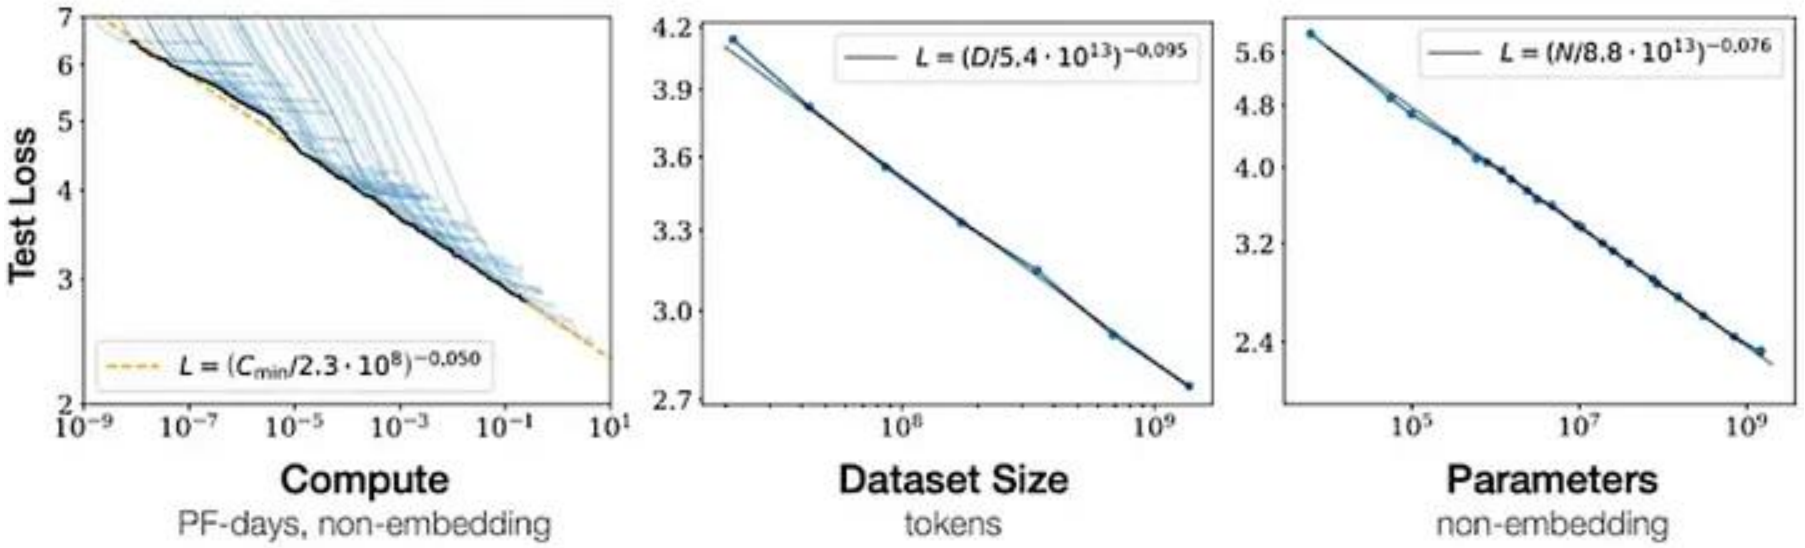
Square Kilometer Array
1376 Po/an (en 2024)



BIG DATA

ONERA
THE FRENCH AEROSPACE LAB

Lois d'échelles



Performances dépendent d'un passage à l'échelle de la quantité de données (loi empirique)

$$perf \propto (N_0/N)^{\alpha}$$

ONERA
THE FRENCH AEROSPACE LAB

Deux pratiques du ML

- ML fournit la solution
  - Prédicteur à partir des données brutes
  - Démarche « end-to-end »
  - Modèles de fondation

- ML est une aide
  - Modèles de substitution (« surrogate »)
  - IA hybride
  - « Physically Informed Neural Networks » (PINNs)

ONERA
THE FRENCH AEROSPACE LAB

MACHINE LEARNING

Problématique générale

ONERA
THE FRENCH AEROSPACE LAB

Dans ce cours

L'apprentissage automatique est:

- une démarche de **conception** d'une **fonction de prédiction**
- par une modélisation ou programmation **non explicite** à partir **d'exemples** (signaux, images, texte, mesures…)

ONERA
THE FRENCH AEROSPACE LAB

Formalisation

- Donnée à interpréter ($\boldsymbol{x}$)
  - Mesures, texte, image, enregistrement, vidéo ou caractéristiques extraites de …
- Prédiction (y)
  - Décision, choix, action, réponse, préférence, groupe, commande, valeur…
- Echantillons ($\mathcal{L} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}$)
  - Exemples de données et de (bonnes) prédictions
  - « Base d'apprentissage »: $\mathcal{L}$
- Hypothèses fortes:
  - Les échantillons contiennent toute l'information exploitable et utile
  - Le futur = le passé: les données à prédire suivent la distribution d'apprentissage

ONERA
THE FRENCH AEROSPACE LAB

Formalisation

Prédicteur = Fonction paramétrique de paramètres $\boldsymbol{W}$

$$y = F(\boldsymbol{x}; \boldsymbol{W})$$

Apprentissage = trouver le $\boldsymbol{W}$ qui **optimise** un critère C

$$\boldsymbol{W} = \arg \min_{\boldsymbol{W}'} C(\boldsymbol{\mathcal{L}}, \boldsymbol{W}')$$

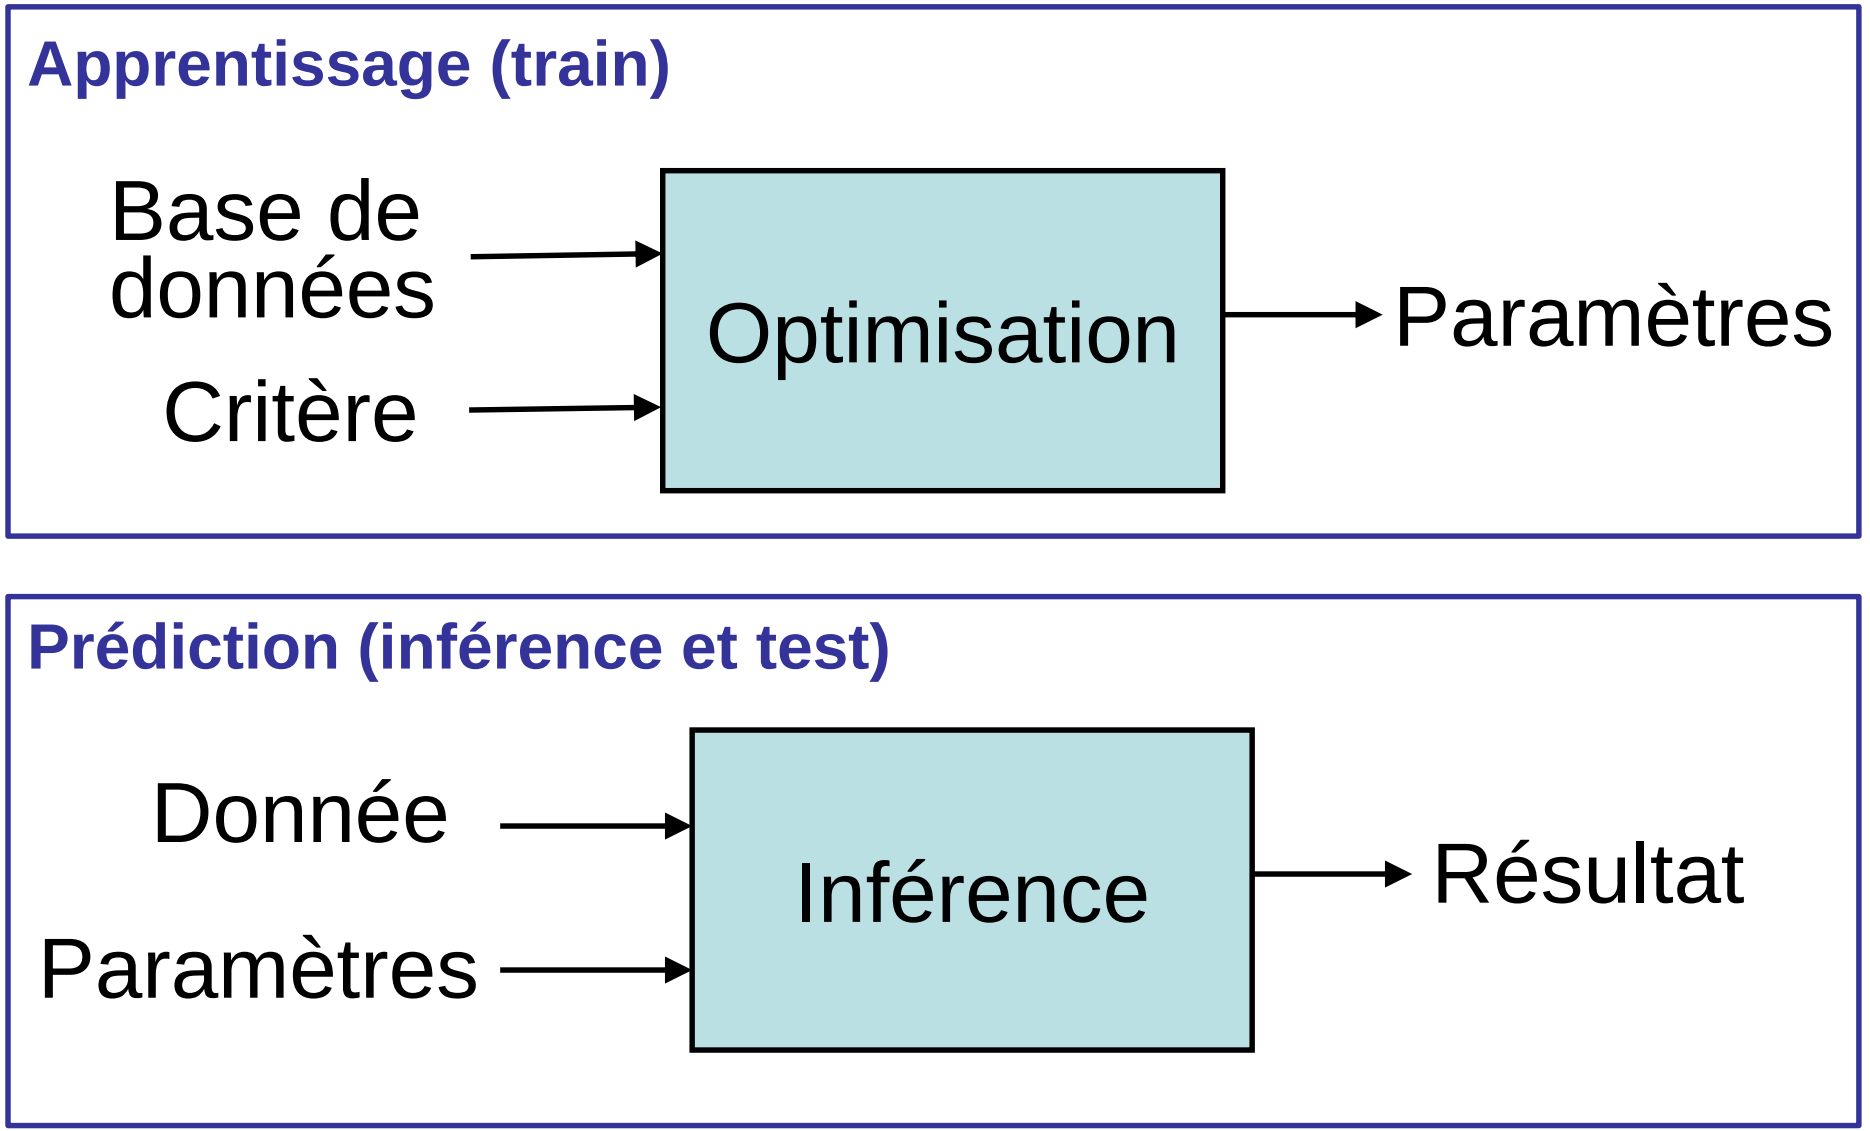
A partir de la **base d'apprentissage** $\boldsymbol{\mathcal{L}} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}$

Le critère C est « **empirique** » = il dépend de données

ex. $C(\boldsymbol{\mathcal{L}}, \boldsymbol{W}) = \sum_i \|y_i - F(\boldsymbol{x}_i; \boldsymbol{W})\|^2$

ONERA
THE FRENCH AEROSPACE LAB

Deux phases



ONERA
THE FRENCH AEROSPACE LAB

Exemple: Reconnaissance de chiffres manuscrits



- Comment définir les éléments ?

$$\boldsymbol{F}, \boldsymbol{W}, \boldsymbol{x}, y$$

- Les fonctions d'apprentissage et de prédiction?

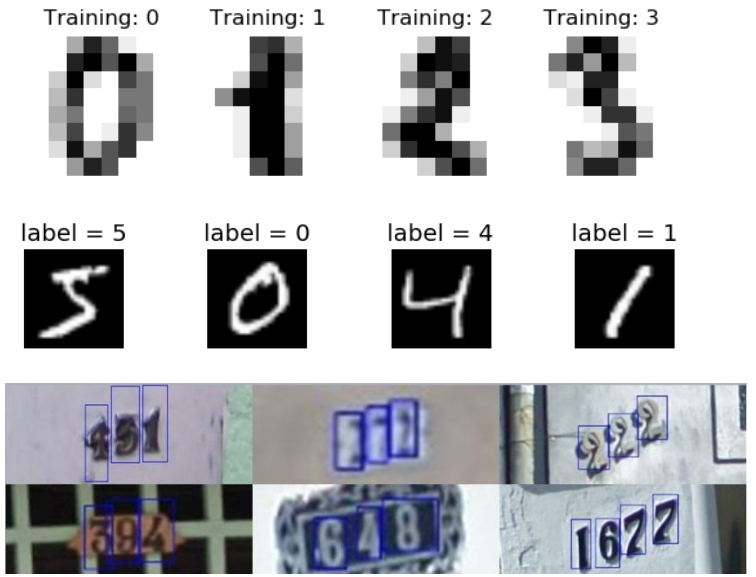
$$\boldsymbol{\mathcal{L}} \mapsto \boldsymbol{W}$$

$$\boldsymbol{W}, \boldsymbol{x} \mapsto y$$

ONERA
THE FRENCH AEROSPACE LAB

Etape 1: choix de la base de données

- Elle existe:
  - Scikit-learn:
  - MNIST:
  - SVHN:

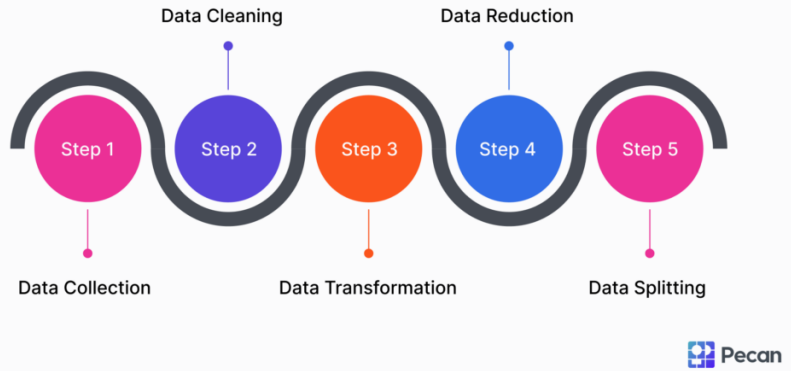


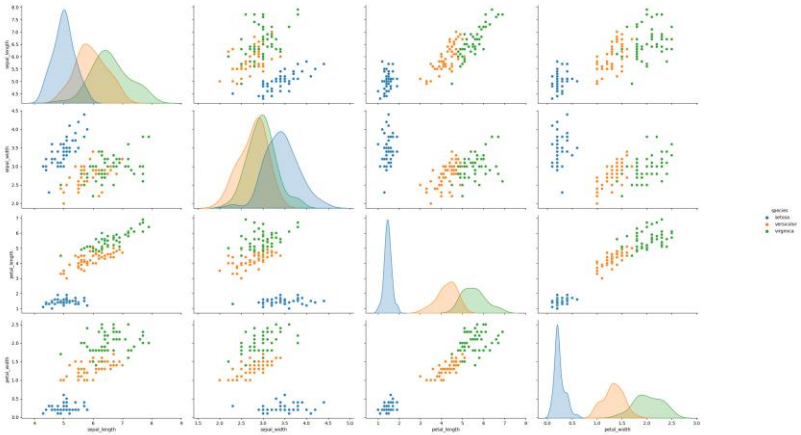
- Il faut la construire:
  - Recueil de données existantes
  - Expérimentations (photos, mesures…)

ONERA
THE FRENCH AEROSPACE LAB

Etape 2: Préparer les données:

- Analyser
  - Quel **contexte**? (grand public, médical, défense…)
  - Quel **format**? (vecteur réel, image, tenseur, série temporelle, graph indicateur binaire…)
  - Quelle **origine**? (mesures réelles, synthèses, humaines…)
  - **Visualiser**: par échantillon, statistiques globales, distributions 2D…
- Prétraiter
  - **Homogénéiser**: nettoyer les données aberrantes, combler les données manquantes, normaliser, recaler, calibrer…
  - **Réduire**: projeter, sous-échantillonner, éliminer les dimensions bruitées…
  - **Transformer**: extraire des caractéristiques informatives et invariantes décomposer dans des bases de représentation,





Remarque: le Deep Learning a révolutionné l'étape de transformation des données en l'intégrant dans l'apprentissage (cours N°5)

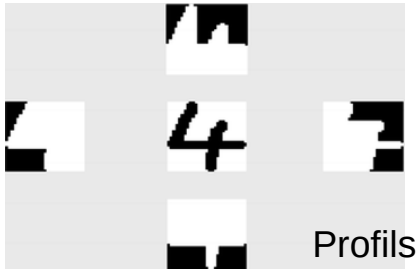
ONERA
THE FRENCH AEROSPACE LAB

Ex: transformer une image en un format réduit

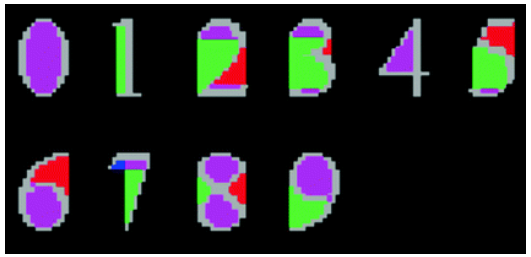


Image (2D)
grande dimension, bruitée, hétérogène

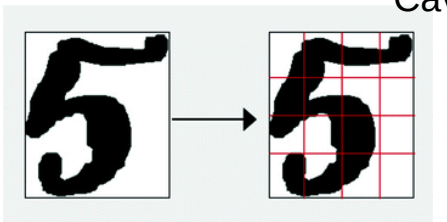
Extraction de caractéristiques
Pré-traitement



Profils



Cavités



Occupation de zones

0
0
0
0
0
1
1
0
0
0
0
1
0
0

***x* = Vecteur**
petite dimension, homogène, « propre »

[Dine et al., 2017]
https://doi.org/10.1007/978-3-319-46568-5_17

ONERA
THE FRENCH AEROSPACE LAB

ML = Travailler avec des données

Différentes activités/métiers

<u>Préparer les données</u>

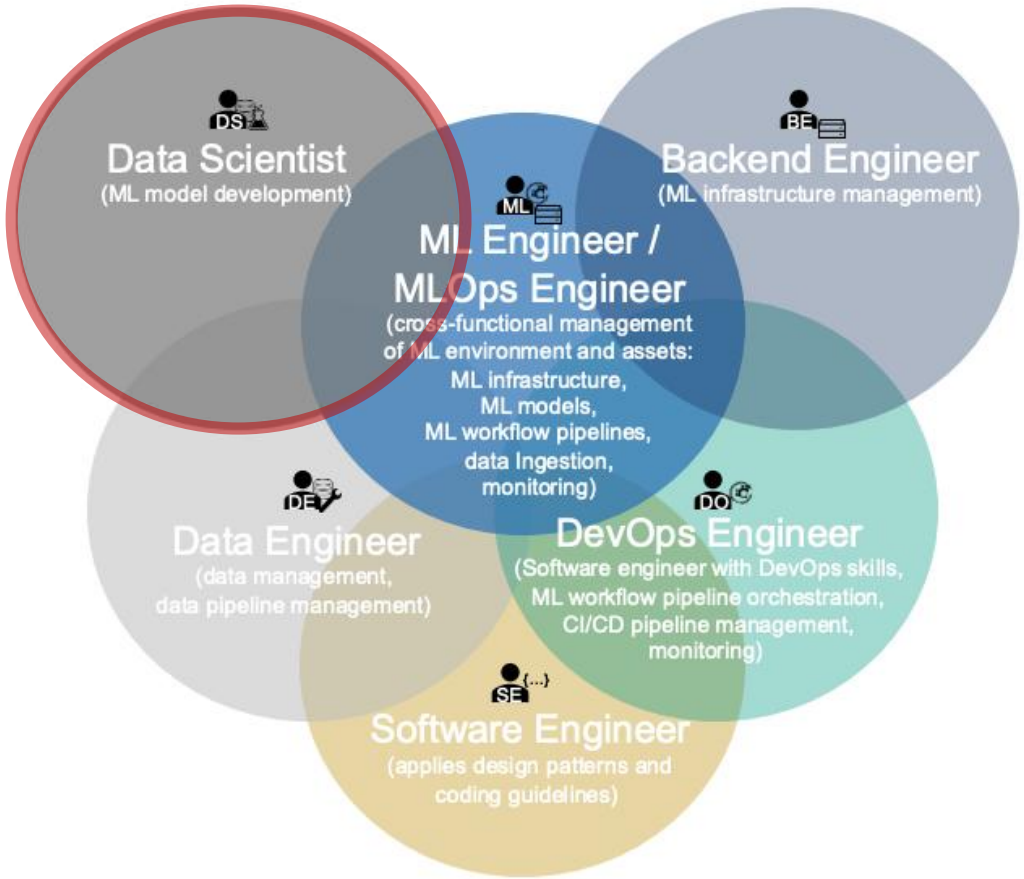
- Etape coûteuse mais indispensable
- Objectif: rendre possible l'apprentissage avec des données
  - Propres, homogènes, recalées, calibrées, organisées, facilement accessibles, renseignées…
- « Data engineering » (un nouveau métier!)

<u>Transformer les données</u>

- Objectif: Extraire l'information des données, leurs caractéristiques (« features »), calculer leur « forme »
- « Data scientist »

ONERA
THE FRENCH AEROSPACE LAB

Les métiers du ML et des données



Kreuzberger, D., Kühl, N., & Hirschl, S. (2022). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. *arXiv preprint arXiv:2205.02302*.

ONERA
THE FRENCH AEROSPACE LAB

Etape 3: choix de l'approche d'apprentissage

- Quelle fonction?
  - Classification
- Quel type d'apprentissage?
  - Apprentissage supervisé (On connait les classes cibles)
- Nature mathématique des données?
  - Vecteurs de taille fixe mais de grandes dimensions (>10)
- Taille de la base de données?
  - Moyenne/Grande (> 10000 exemples)
- Modèle de prédicteur?
  - Arbres de décision, SVM, Réseaux de neurones…

ONERA
THE FRENCH AEROSPACE LAB

Types de prédiction

- **Classification**
  - Binaire: spam / non spam
  - Identification: « tata Monique »
- **Régression**
  - Prédiction de température, de cours de bourse
  - Localisation d'objet dans image
  - Commande
- **Structure**
  - Graphe des articulations d'une personne
- **Regroupement**
  - Photos dans base de données personnelle
- **Texte**
  - « C'est un chat qui saute sur une table. »

ONERA
THE FRENCH AEROSPACE LAB

Types d'apprentissage

- **Apprentissage supervisé**
  - Les données d'apprentissage contiennent les objectifs de prédiction (annotations)
- **Apprentissage non supervisé**
  - Les données d'apprentissage sont brutes
- **Apprentissage par renforcement**
  - Les prédictions sont issues d'une séquence d'actions et sont caractérisées par un mesure de qualité (« reward »)
- **Apprentissage semi-supervisé**
  - Les données d'apprentissage sont partiellement annotées
- **Apprentissage par transfert**
  - Les données d'apprentissage sont proches du problème visé

ONERA
THE FRENCH AEROSPACE LAB

Modèle de prédicteur

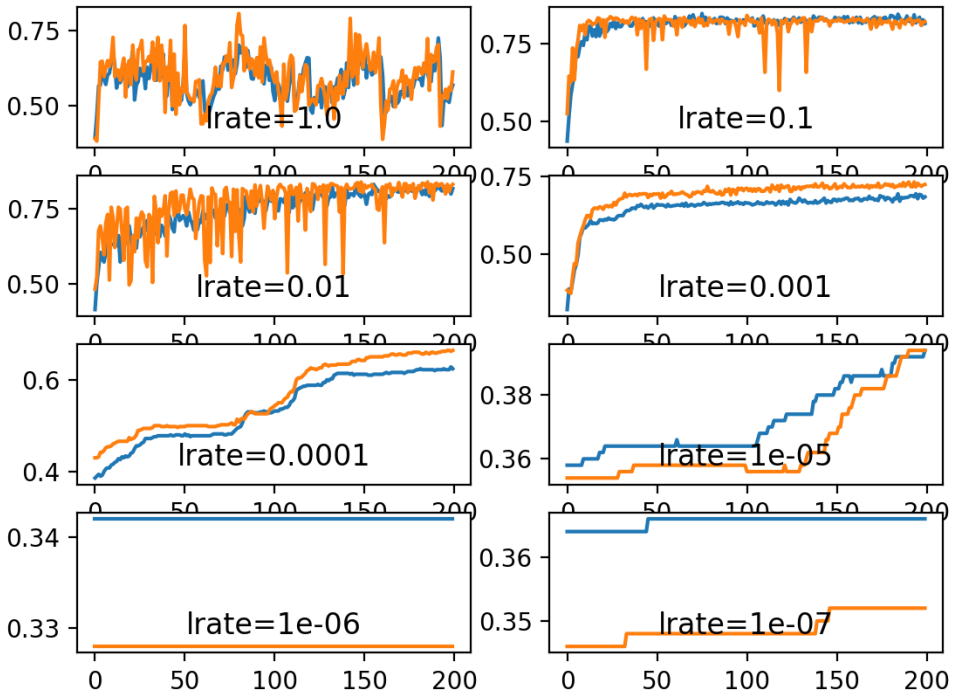
- Dépend de la forme des données (vecteurs, listes, réels/discret) et du type de prédiction

- Exemples
  - Plus proches voisins
  - Machines à vecteurs de supports (SVM)
  - Arbre de décision
  - Ensembles de classifieurs (forêts aléatoires, « boosting »…)
  - Réseaux de neurones
  - Modèles probabilistes (Réseaux bayésiens, Chaînes ou champs de Markov…)
  - Règles/Programmation logique
  - Etc.

ONERA
THE FRENCH AEROSPACE LAB

Etape 4: apprentissage

- Définir un espace fonctionnel et un critère paramétrique (coût, énergie…)
- Appliquer un **optimiseur** et régler ses paramètres
- Vérifier que l'apprentissage se passe bien
  - Valeur du critère
  - Convergence
  - Paramètres du prédicteur
  - …



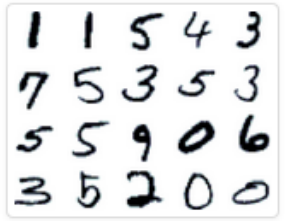
ONERA
THE FRENCH AEROSPACE LAB

Optimisation

- **Optimisation convexe**
  - Ex. Minimisation séquentielle de problème quadratique
- **Optimisation stochastique**
  - Ex. Descente de gradient stochastique, Algorithmes génétiques
- **Optimisation sous contraintes**
  - Ex. Programmation linéaire
- **Optimisation combinatoire**
  - Ex. Algorithmes gloutons

ONERA
THE FRENCH AEROSPACE LAB

Etape 5: évaluation



MNIST 50 results collected

Units: error %

> Classify handwriten digits. Some additional results are available on the original dataset page.

Result	Method	Venue	Details
0.21%	Regularization of Neural Networks using DropConnect	ICML 2013	
0.23%	Multi-column Deep Neural Networks for Image Classification	CVPR 2012	
0.23%	APAC: Augmented PAttern Classification with Neural Networks	arXiv 2015	
0.24%	Batch-normalized Maxout Network in Network	arXiv 2015	Details
0.29%	Generalizing Pooling Functions in Convolutional Neural Networks: Mixed, Gated, and Tree	AISTATS 2016	Details
0.31%	Recurrent Convolutional Neural Network for Object Recognition	CVPR 2015	
0.31%	On the Importance of Normalisation Layers in Deep Learning with Piecewise Linear Activation Units	arXiv 2015	

ONERA
THE FRENCH AEROSPACE LAB

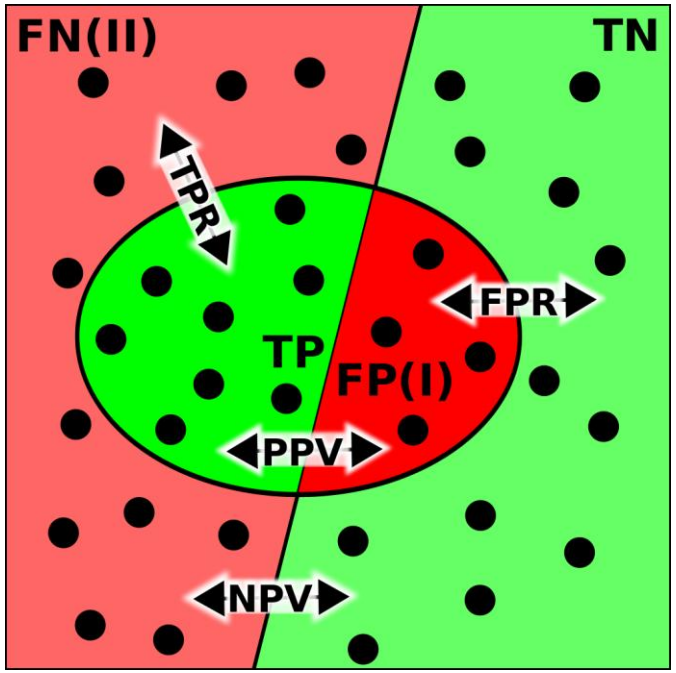
Métriques d'évaluation

- Dépend du type de prédiction

- Classification
  - Taux d'erreur moyen
  - Matrice de confusion
  - Précision/rappel
  - Courbe ROC

- Régression
  - Erreur quadratique

- Détection
  - Taux de recouvrement moyen



https://scikit-learn.org/stable/modules/model_evaluation.html

https://en.wikipedia.org/wiki/Evaluation_of_binary_classifiers

ONERA
THE FRENCH AEROSPACE LAB

Train et Test

- Apprentissage (« train »)
  - Exploité pour calculer le prédicteur
  - C'est un moyen de modélisation

- Evaluation (« test »)
  - Utilisé pour estimer l'erreur de prédiction une fois l'apprentissage achevé
  - C'est la situation réelle (ou censée l'être), l'inférence
  - Données pour lesquelles on veut une bonne prédiction
  - NE PAS UTILISER POUR L'APPRENTISSAGE

- Validation
  - Utilisé pour simuler/estimer l'erreur de test pendant l'apprentissage

ONERA
THE FRENCH AEROSPACE LAB

Résumé des étapes de conception

1. Constituer des bases de données
2. Préparer les données: Analyser, visualiser, prétraiter, transformer, extraire, constituer les ensembles train/test
3. Concevoir le modèle (type de prédicteur, principe d'apprentissage)
4. Définir un critère et Optimiser (l'apprentissage proprement dit)
5. Evaluer

ONERA
THE FRENCH AEROSPACE LAB

ML POUR CLASSIFICATION

Modélisation probabiliste

ONERA
THE FRENCH AEROSPACE LAB

Classification

- Classification = choisir **une** hypothèse parmi un ensemble donné

- Aujourd'hui: classification **binaire**:
  - Deux hypothèses à séparer: vrai/faux, malade/sain…
  - Rend compte de multiples situations pratiques de décision
  - Théorie plus facile à développer

- Deux stratégies de conception:
  - Modéliser les données pour décider: approche **générative**
  - Décider directement à partir des données: approche **discriminative**

- Base statistique et probabiliste

ONERA
THE FRENCH AEROSPACE LAB

Formalisme (suite)

- Fonction de décision (ou de prédiction):

$$y = F(\boldsymbol{x}; W)$$

Deux visions:
fonctions vs. probabilités

$\boldsymbol{x} \in \mathbb{R}^{\boldsymbol{d}}$, $y \in \{0,1\}$ ou $\{1,2 \dots C\}$

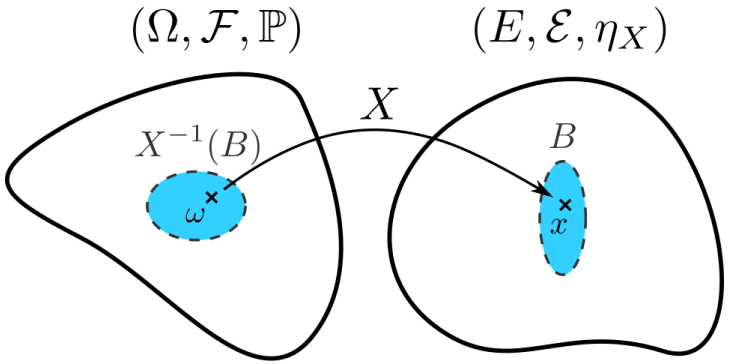
- On considère les données $\boldsymbol{x}, y$ comme des **variables aléatoires**

- Base d'apprentissage: échantillons $\boldsymbol{\mathcal{D}} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}$ de la loi $P(\boldsymbol{x}, y)$

- Les échantillons sont Indépendants Identiquement Distribués (i.i.d.)

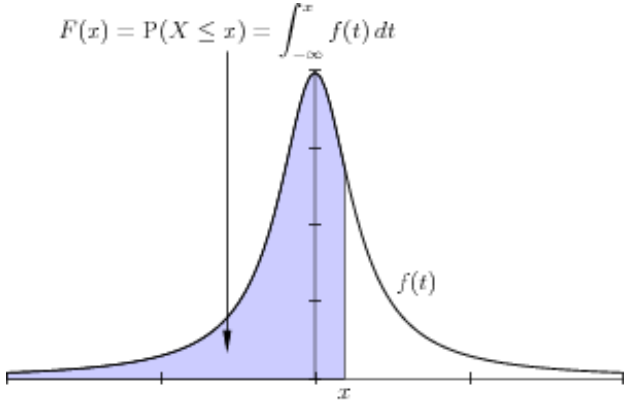
ONERA
THE FRENCH AEROSPACE LAB

Probabilités / statistiques (rappels)

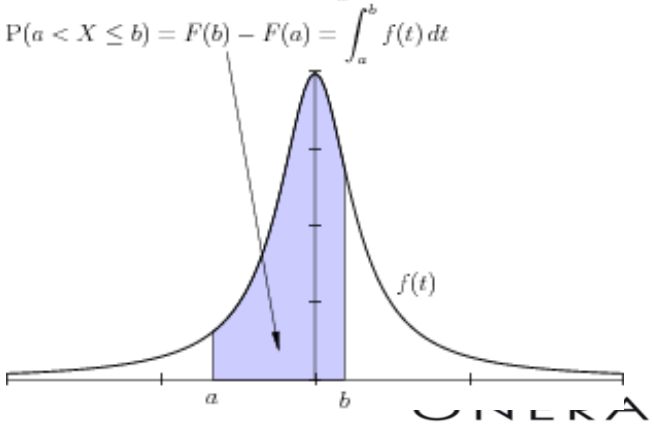


- Variable aléatoire
  - Fonction X d'un espace probabilisé vers un espace mesurable
  - Mesure de probabilité: $\mathbb{P}_X(B) = \mathbb{P}[X^{-1}(B)] = \mathbb{P}(X \in B)$
  - En pratique, $E = \mathbb{R}^D$ (continu) ou $\{1, \dots C\} \in \mathbb{N}$ (discret)

- Distribution de probabilité (cas continu)
  - Fonction de répartition: $F_X(x) = \mathbb{P}(X \leq x)$
  - Densité de probabilité: $f_X(x) = \frac{dF_X(x)}{dx}$



- Mesures
  - Espérance mathématique: $E_X[g(X)] = \int g(x) f_X(x)$
    - Moyenner des phénomènes ou des quantités
  - Moments: Moyenne, variance… $E_X[X^p] = \int_{-\infty}^{+\infty} x^p f_X(x)$
    - Résumer/analyser la distribution



ONERA
THE FRENCH AEROSPACE LAB

Combiner/associer des variables aléatoires

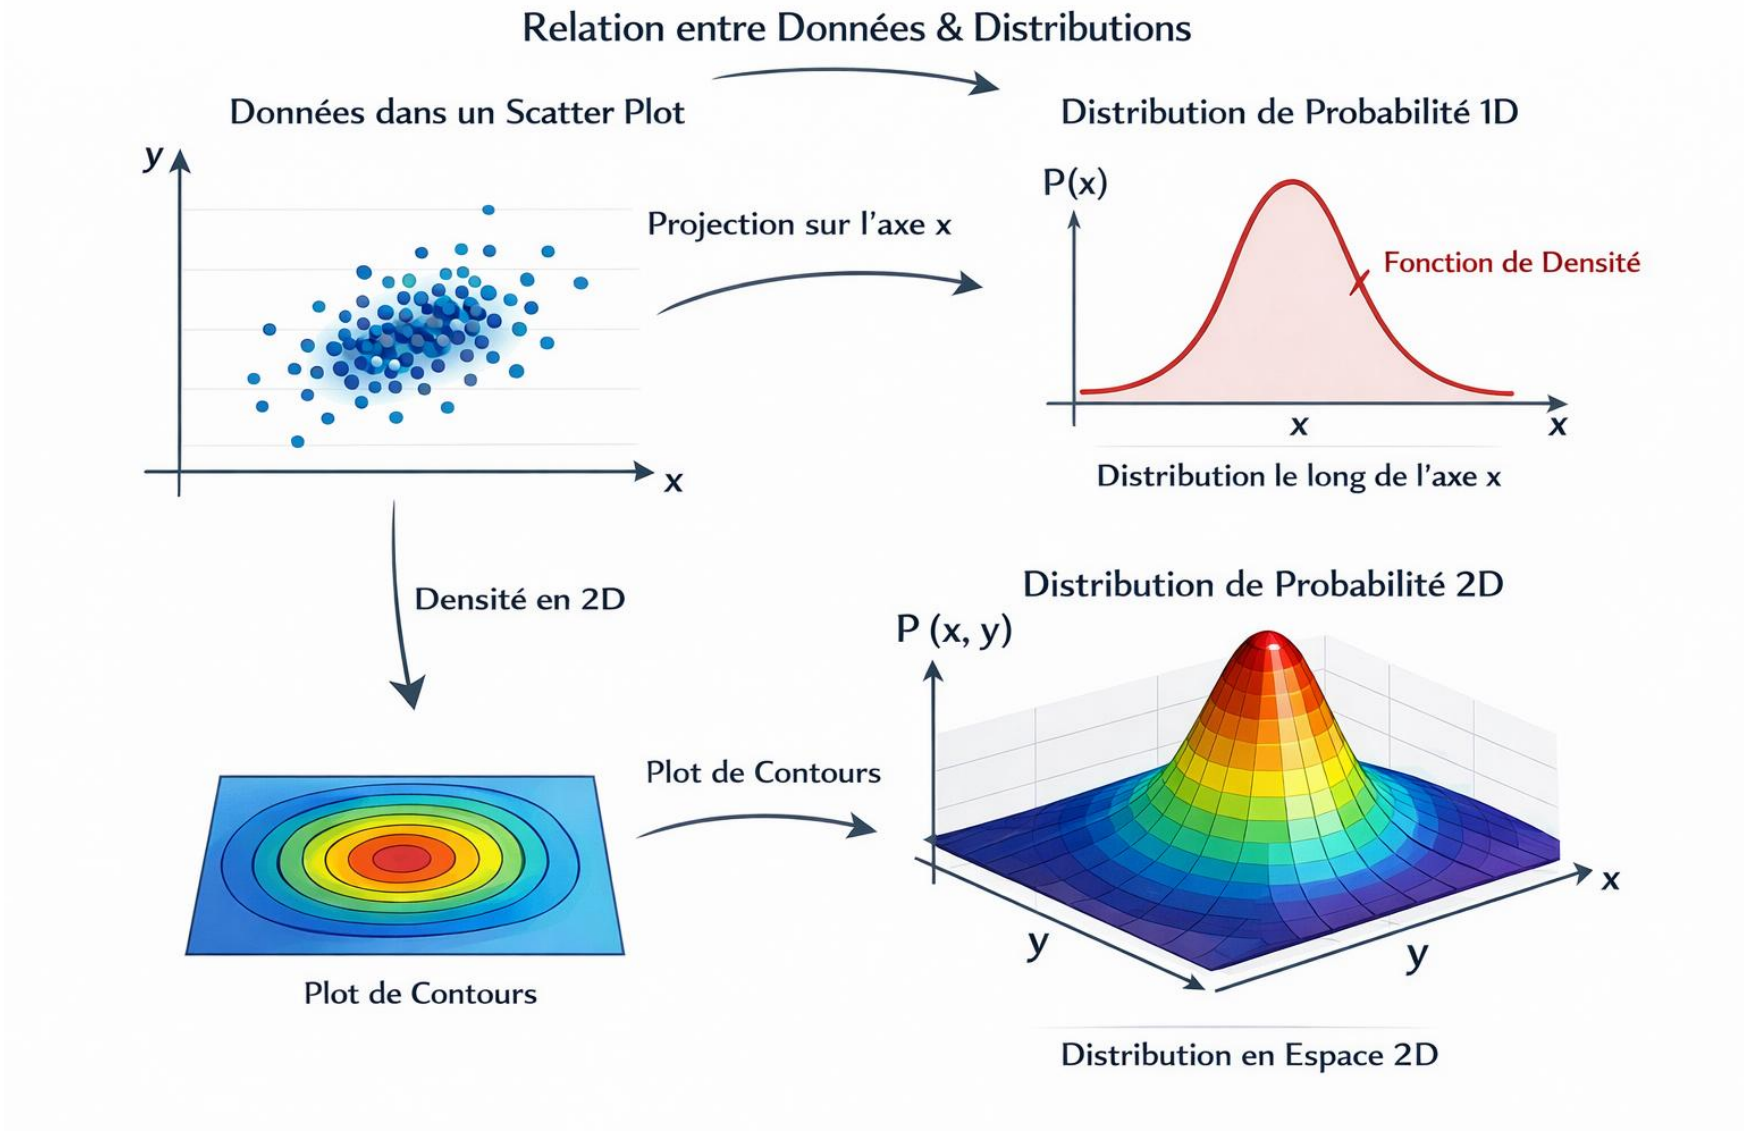
- Plusieurs types de lois de probabilités:
  - $P(\boldsymbol{x}, y)$: loi jointe
  - $P(\boldsymbol{x})$: loi a priori sur les données (« comment est le monde »)
  - $P(y)$: loi a priori sur les prédictions (« quel sens donner au monde »)
  - $P(\boldsymbol{x} \mid y)$: vraisemblance conditionnelle
  - $P(y \mid \boldsymbol{x})$: loi a posteriori

- Conditionnement
  - $P(\boldsymbol{x}, y) = P(\boldsymbol{x}|y)P(y) = P(y|\boldsymbol{x})P(\boldsymbol{x})$
  - Permet de simplifier la modélisation en décomposant la loi jointe

- Indépendance
  - Générale: $P(x, x') = P(x)P(x')$
  - Conditionnelle: $P(x, x'|y) = P(x|y)P(x'|y)$
  - Hypothèses de modélisation, mais potentiellement vérifiable empiriquement (en fait rarement)

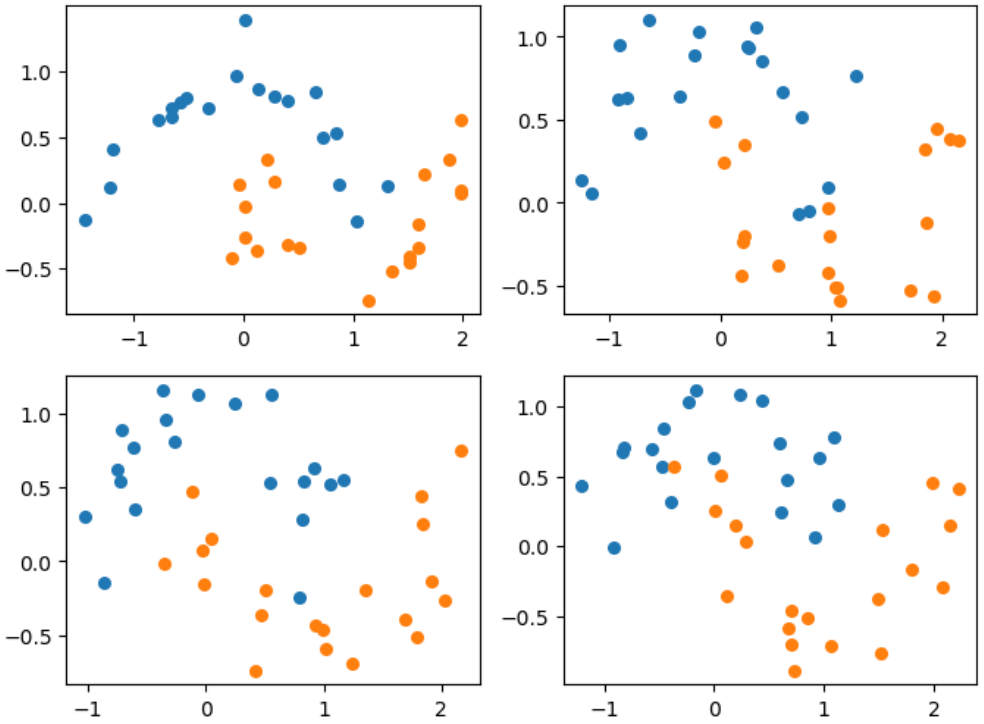
ONERA
THE FRENCH AEROSPACE LAB

Données et distribution de probabilité

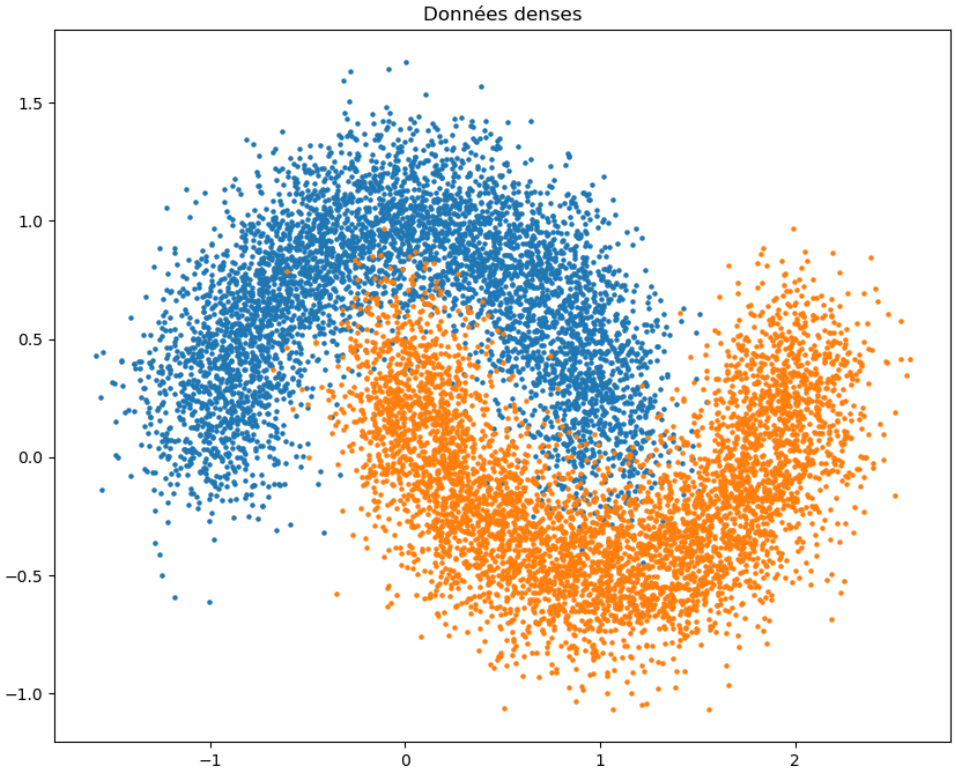


ONERA
THE FRENCH AEROSPACE LAB

Echantillons et variance



Quatre tirages différents (50 échantillons)

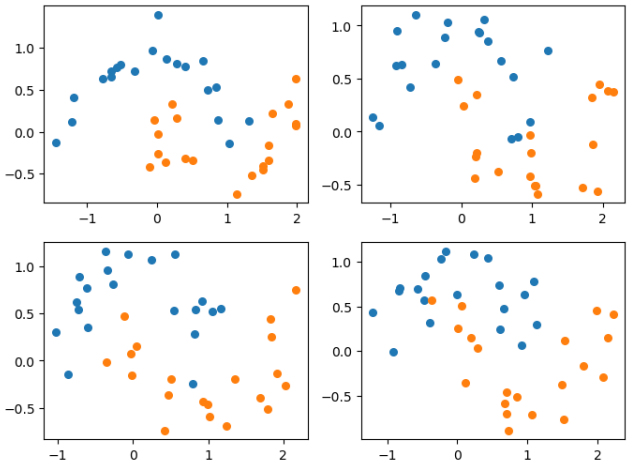


Un tirage (10000 échantillons)

ONERA
THE FRENCH AEROSPACE LAB

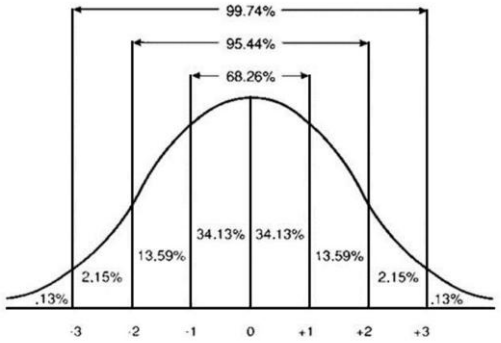
Probabilités / statistiques (rappels)

- Données
  - La « matière » originelle du ML: pas de structure ou d'organisation
  - Hypothèse = échantillons d'une distribution (que l'on imagine exister…)
  - Train et test: deux ensembles d'échantillons de la même distribution



A partir de la modélisation probabiliste…

- Estimation de paramètres
  - Maximum de vraisemblance: meilleure explication
  - Loi des grands nombres: convergence vers la valeur moyenne
- Incertitude: relier quantités estimées, modèles probabilistes et données
  - Intervalles de confiance: compromis précision et confiance
  - Inégalités de concentration (Markov, Chebyshev, Chernoff, Hoeffding…): contrôler les écarts aux estimations
  - Tests statistiques: mesurer la validité d'une hypothèse



$$\mathbb{P}(X \geq t) \leq E_X[X]/t$$

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_i X_i - E_X[X]\right| \geq t\right) \leq 2\exp(-2nt^2)$$

ONERA
THE FRENCH AEROSPACE LAB

Stratégie 1: Modéliser les données pour décider

1. Trouver une représentation des données (modèle paramétrique)
2. Construire une « bonne » fonction de prédiction à partir de ce modèle

Apprentissage = estimation des paramètres du modèle à partir de données

- Une « bonne » fonction de prédiction dépend de la nature du modèle et de l'impact potentiel des erreurs

- Modèle probabiliste: on peut générer (échantillonner) des données

➔ On parle d'approche « générative » (attention: différent de l'IA générative des médias!)

- On peut considérer le problème comme une estimation de la loi jointe $P(\boldsymbol{x}, y)$ ou des vraisemblances $P(\boldsymbol{x}|y)$ et loi a priori $P(y)$.

ONERA
THE FRENCH AEROSPACE LAB

Théorie Bayésienne de la décision

- Classification: $y \in \{1,2 \dots C\}$ est une étiquette (classe)
- On cherche à prédire une unique hypothèse y^* à partir de $\boldsymbol{x}$

$$F: \boldsymbol{x} \mapsto y^*$$

- On définit une fonction qui caractérise le coût (ou risque) de mauvaise décision: $l(y, y^*)$
- On cherche à **minimiser** son espérance, i.e. sa valeur moyenne:

$$E_{x,y}[l(y, F(x))] = \int_{x,y} l\big(y, F(x)\big) P(x, y)$$

- Un coût usuel est $l(y, y') = 1 - 1_{y=y'}$ (risque 0/1 = comptage des erreurs)
- On peut montrer que la fonction de **décision optimale** est le **« classifieur bayésien »**:

$$F(x) = \arg\max_y P(y \mid \boldsymbol{x})$$

Remarque: la démonstration repose sur la factorisation:

$$E_{x,y}[l(y, F(x))] = \int_x P(x) \int_{y|x} l\big(y, F(x)\big) P(y|x)$$

ONERA
THE FRENCH AEROSPACE LAB

Théorie Bayésienne de la décision

- Deux questions:
  - Comment calculer $P(y \mid \boldsymbol{x})$ = apprentissage
  - Comment trouver le max = prédiction
- « Astuce »: utiliser la loi de Bayes

$$P(y \mid \boldsymbol{x}) = \frac{P(\boldsymbol{x} \mid y)\, P(y)}{P(\boldsymbol{x})}$$

- On connait en général la fréquence d'occurrence des classes y
- On sait plus facilement calculer la **vraisemblance**: $P(\boldsymbol{x} \mid y)$

  « Si je sais dans quelle classe je suis, je sais décrire le comportement/distribution de mes données »

- Le max sur y ne dépend que de $P(\boldsymbol{x} \mid y)$ et $P(y)$

$$F(x) = \arg\max_{y} P(\boldsymbol{x} \mid y) P(y)$$

ONERA
THE FRENCH AEROSPACE LAB

Exemple : Modèle gaussien multivarié

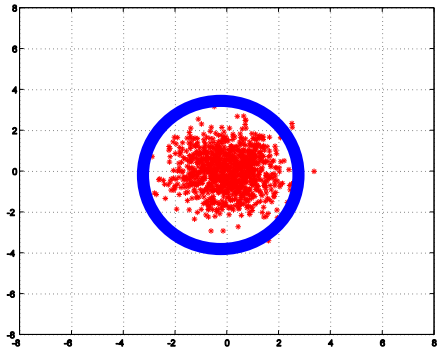
- Un exemple élémentaire (mais utile) de vraisemblance:

$$\mathrm{P}(\boldsymbol{x};\boldsymbol{\mu},\boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2}\sqrt{|\boldsymbol{\Sigma}|}} \exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right]$$

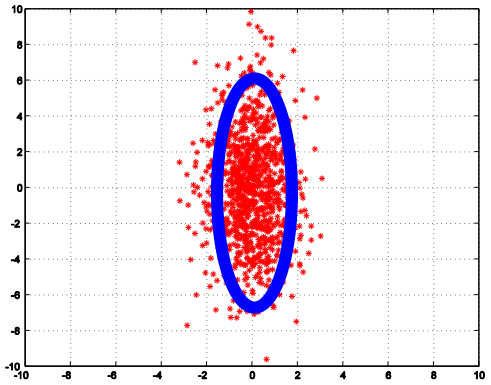
où $\boldsymbol{x} = [x_1, x_2 \ldots x_d] \in \mathbb{R}^d$

- Permet de décrire les corrélations entre dimensions (moments d'ordre 2).

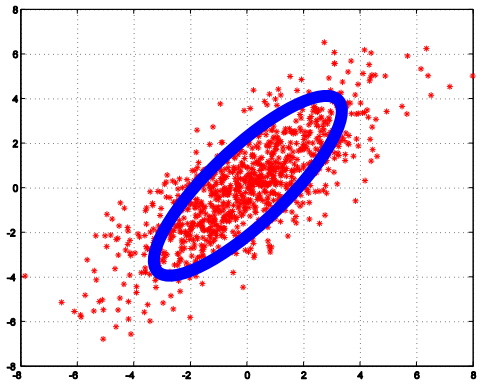
$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 9 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} = R \begin{bmatrix} 9 & 0 \\ 0 & 1 \end{bmatrix} R^{-1}$$



ONERA
THE FRENCH AEROSPACE LAB

« Apprentissage » du modèle gaussien

- Log-vraisemblance d'un échantillon $\boldsymbol{X} = \{\boldsymbol{x}_1, \boldsymbol{x}_2 \ldots \boldsymbol{x}_N\}$

$$\log \mathrm{P}(\boldsymbol{X}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = cste - \frac{N}{2} \log |\boldsymbol{\Sigma}| - \sum_{i=1}^{N} (\boldsymbol{x_i} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\boldsymbol{x_i} - \boldsymbol{\mu})$$

- L'estimateur du maximum de vraisemblance donne:

$$\widehat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{x}_i$$

et

$$\widehat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_{i=1}^{N} (\boldsymbol{x_i} - \widehat{\boldsymbol{\mu}})(\boldsymbol{x_i} - \widehat{\boldsymbol{\mu}})^t$$

- Remarques:
  1. L'estimateur de la covariance est biaisé. On normalise en général par $\frac{1}{N-1}$.
  2. On peut définir des estimateurs plus robustes qui gèrent les données aberrantes

ONERA
THE FRENCH AEROSPACE LAB

Construction de la décision

- Problème à deux classes: décider consiste à calculer le signe du log-ratio!

$$\log \frac{P(\boldsymbol{x};\boldsymbol{\mu}_1,\boldsymbol{\Sigma}_1)P(y_1)}{P(\boldsymbol{x};\boldsymbol{\mu}_2,\boldsymbol{\Sigma}_2)P(y_2)} \underset{2}{\overset{1}{\gtrless}} 0$$

- En développant, on obtient une fonction de décision de la forme:

$$(\boldsymbol{x}-\boldsymbol{\mu}_1)'\boldsymbol{\Sigma}_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) - (\boldsymbol{x}-\boldsymbol{\mu}_2)'\boldsymbol{\Sigma}_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2) + cste \underset{2}{\overset{1}{\gtrless}} 0$$

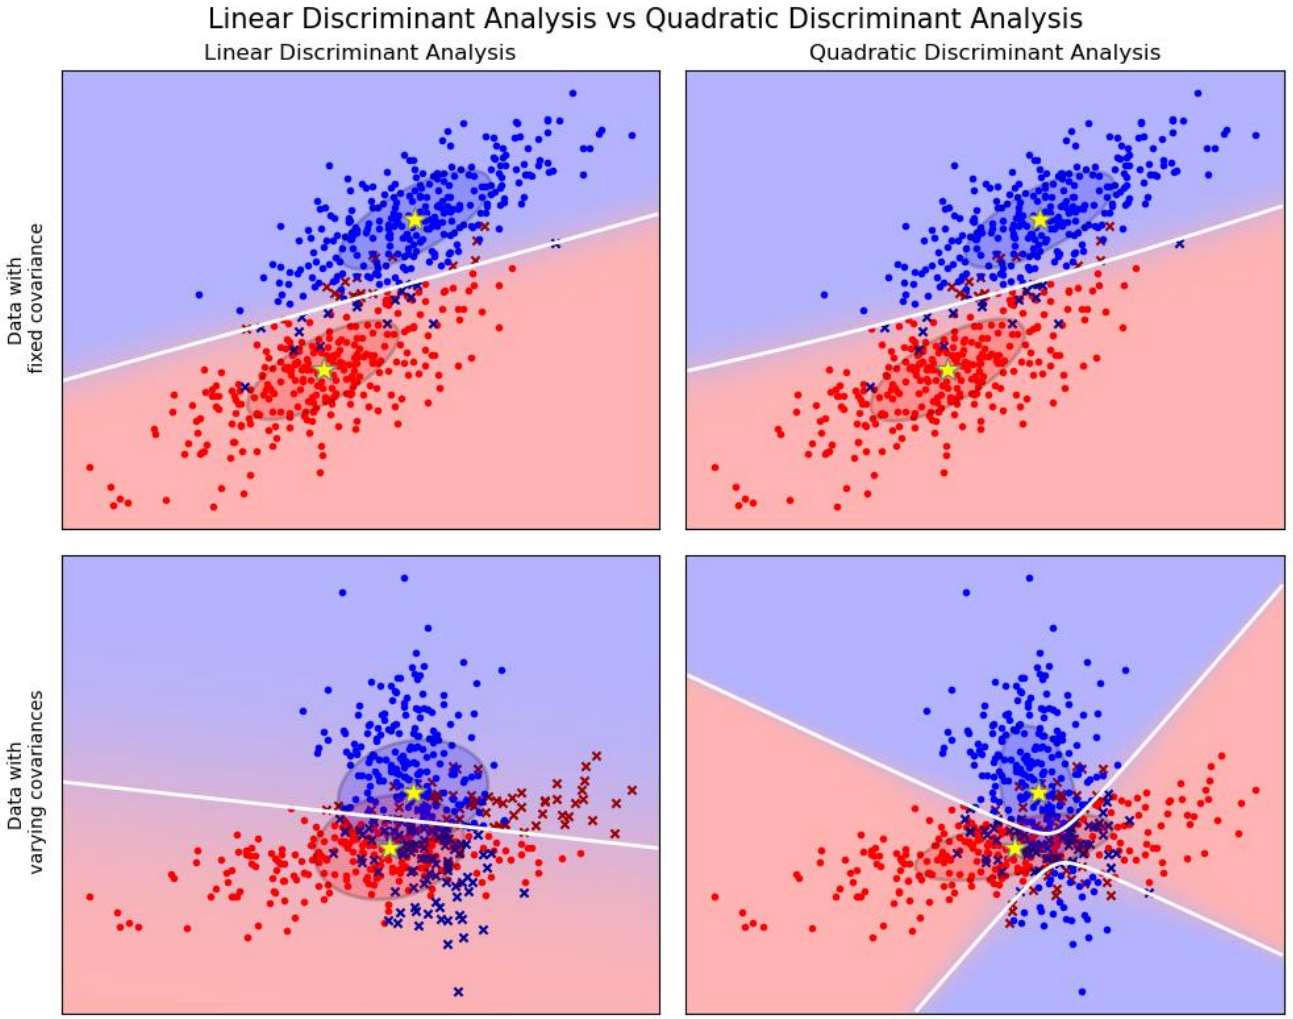
- C'est une forme quadratique.
- Remarque: si l'on contraint les deux populations à avoir la même covariance $\boldsymbol{\Sigma}$, on obtient une forme linéaire:

$$\boldsymbol{x}'\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2) + cste \underset{2}{\overset{1}{\gtrless}} 0$$

- On parle de « séparatrice »: la forme (quadratique ou linéaire) sépare l'espace en deux zones.

ONERA
THE FRENCH AEROSPACE LAB

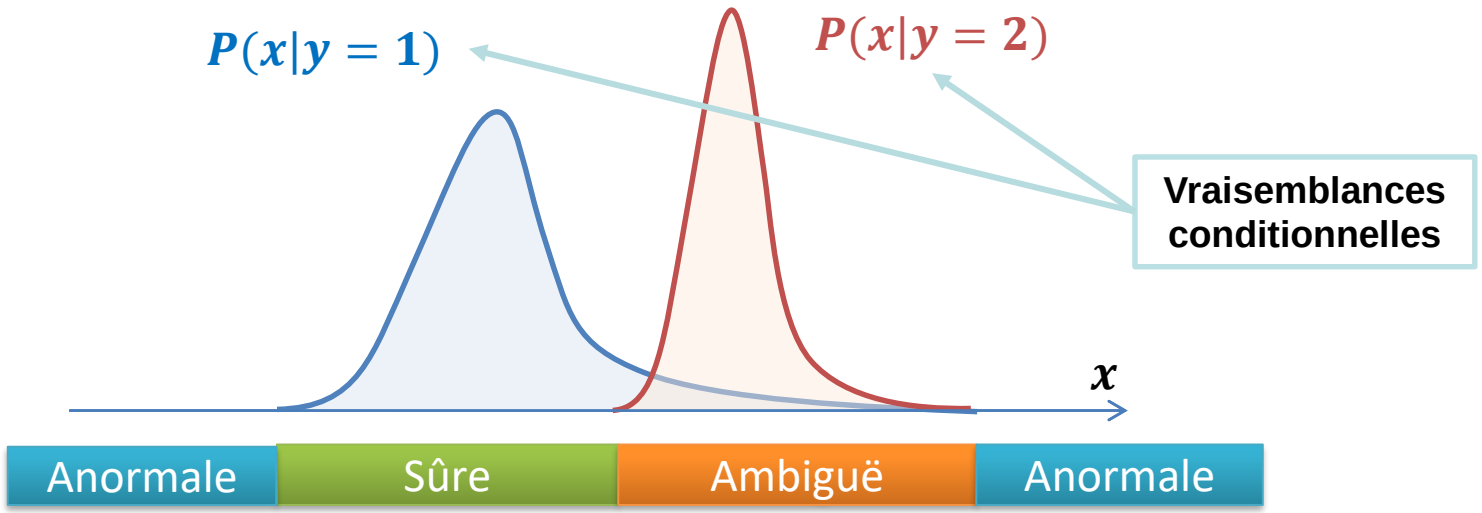
Exemple en 2D



https://scikit-learn.org/stable/modules/lda_qda.html

ONERA
THE FRENCH AEROSPACE LAB

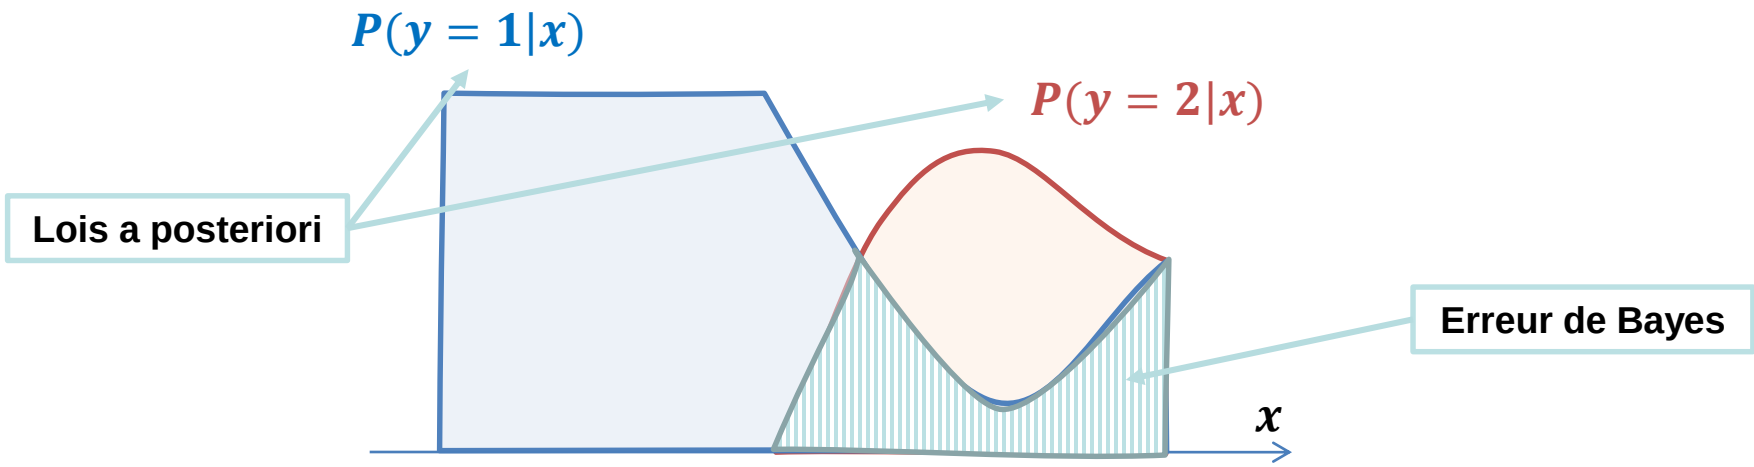
Différentes sources d'erreur



- Certaines données sont ambiguës: on ne peut prendre de décision sûre sur la classe.
- Certaines données sont « impossibles » et sont considérées comme anormales si elles surviennent: elles sont « hors support ».

ONERA
THE FRENCH AEROSPACE LAB

Une erreur incompressible



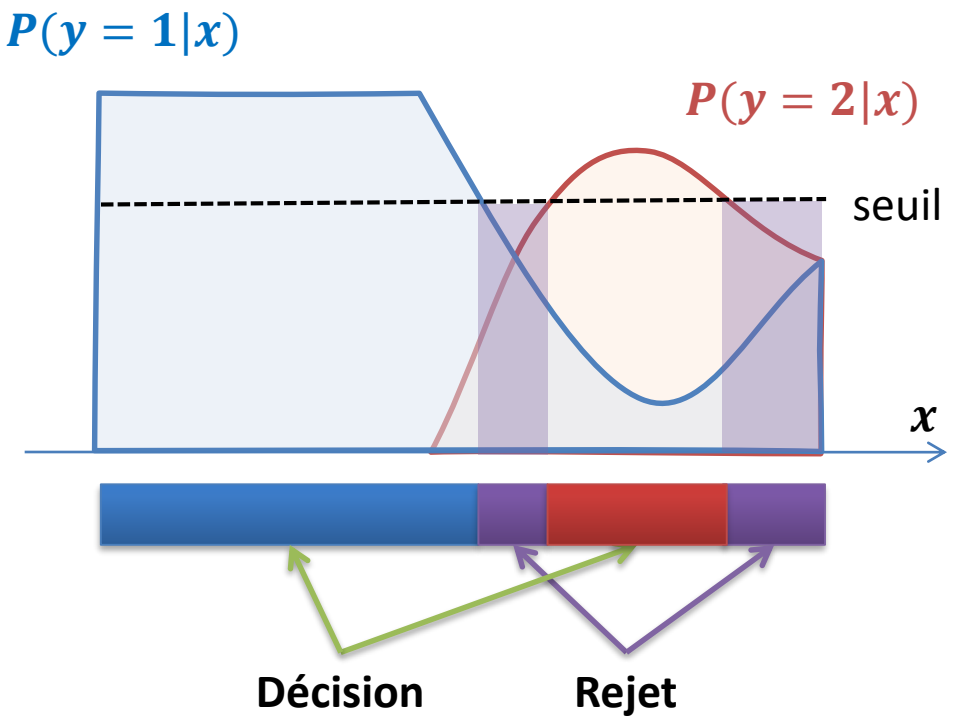
- Pour une décision bayésienne (argmax sur la loi a posteriori), l'erreur est alors

$$\text{error}_{\text{Bayes}} = E_x[1 - \max_k P(y = k|x)]$$

- C'est l'erreur minimale que peut réaliser un prédicteur.
- Rem: c'est un concept théorique, difficile à calculer en pratique

ONERA
THE FRENCH AEROSPACE LAB

Rejet sur loi a posteriori



- On peut contrôler le processus de décision en seuillant sur la loi a posteriori, et en décidant de ne pas décider si en dessous du seuil (« rejet »).
- Intérêt: on diminue le taux d'erreur mais on décide moins souvent.

ONERA
THE FRENCH AEROSPACE LAB

Remarques sur la modélisation bayésienne gaussienne

- Dans des espaces de grandes dimensions, il n'est pas possible d'estimer correctement la covariance → modèle gaussien imprécis.

➔ *Peut-on simplifier la modélisation des données?*

➔ Approche bayésienne naïve

- On peut souvent faire comme si la distribution était gaussienne même si ce n'est pas vrai: ce qui importe est de trouver une bonne fonction de décision (voir TD)

➔ *Peut-on trouver la fonction de décision sans modélisation des données?*

➔ Approche discriminative

ONERA
THE FRENCH AEROSPACE LAB

Approche Bayésienne Naïve

- Que faire pour des espaces à grande dimension?
- Calcul de la loi conditionnelle: hypothèse d'indépendance conditionnelle.

$$P(x_1, x_2 \dots x_d|y) = P(x_1|x_2 \dots x_d, y)P(x_2 \dots x_d|y)$$
$$= P(x_1|y)P(x_2 \dots x_d|y)$$
$$= P(x_1|y)P(x_2|y) \dots P(x_d|y)$$

- On calcule la vraisemblance globale dimension par dimension

➔ Problème 1D, modèles plus faciles à estimer (gaussien, binomial, histogrammes, mélange de gaussiennes…)

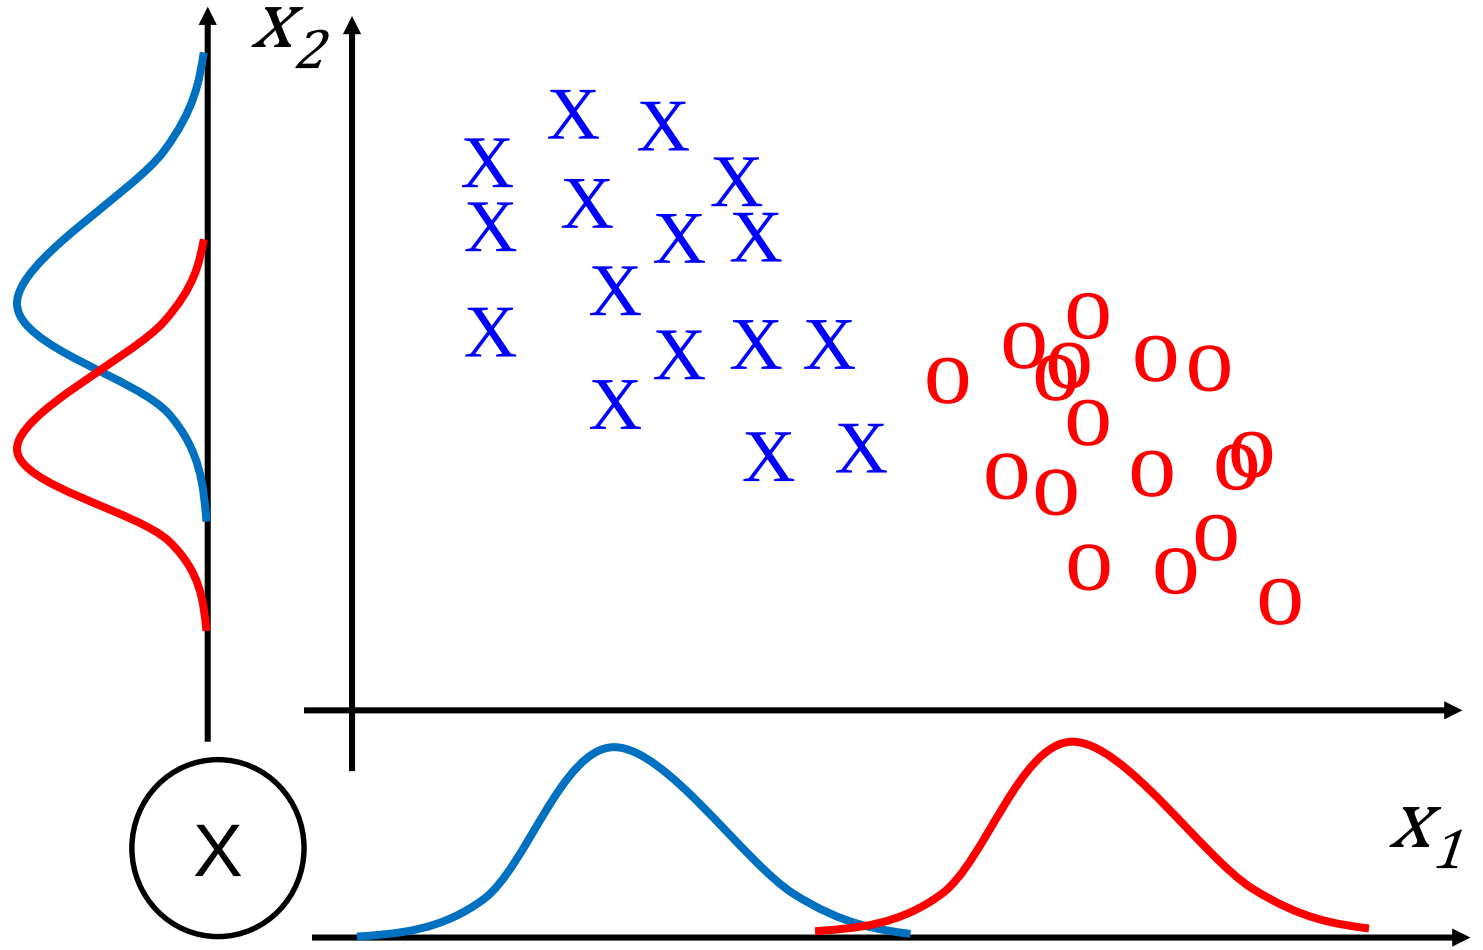
- En pratique, on calcule plutôt la log-vraisemblance pour des questions de stabilité numérique

$$\log P(\boldsymbol{x}|y) = \sum_i \log P(x_i|y)$$

$$y^* = \arg\max_y \log P(\boldsymbol{x} \mid y) + \log P(y)$$

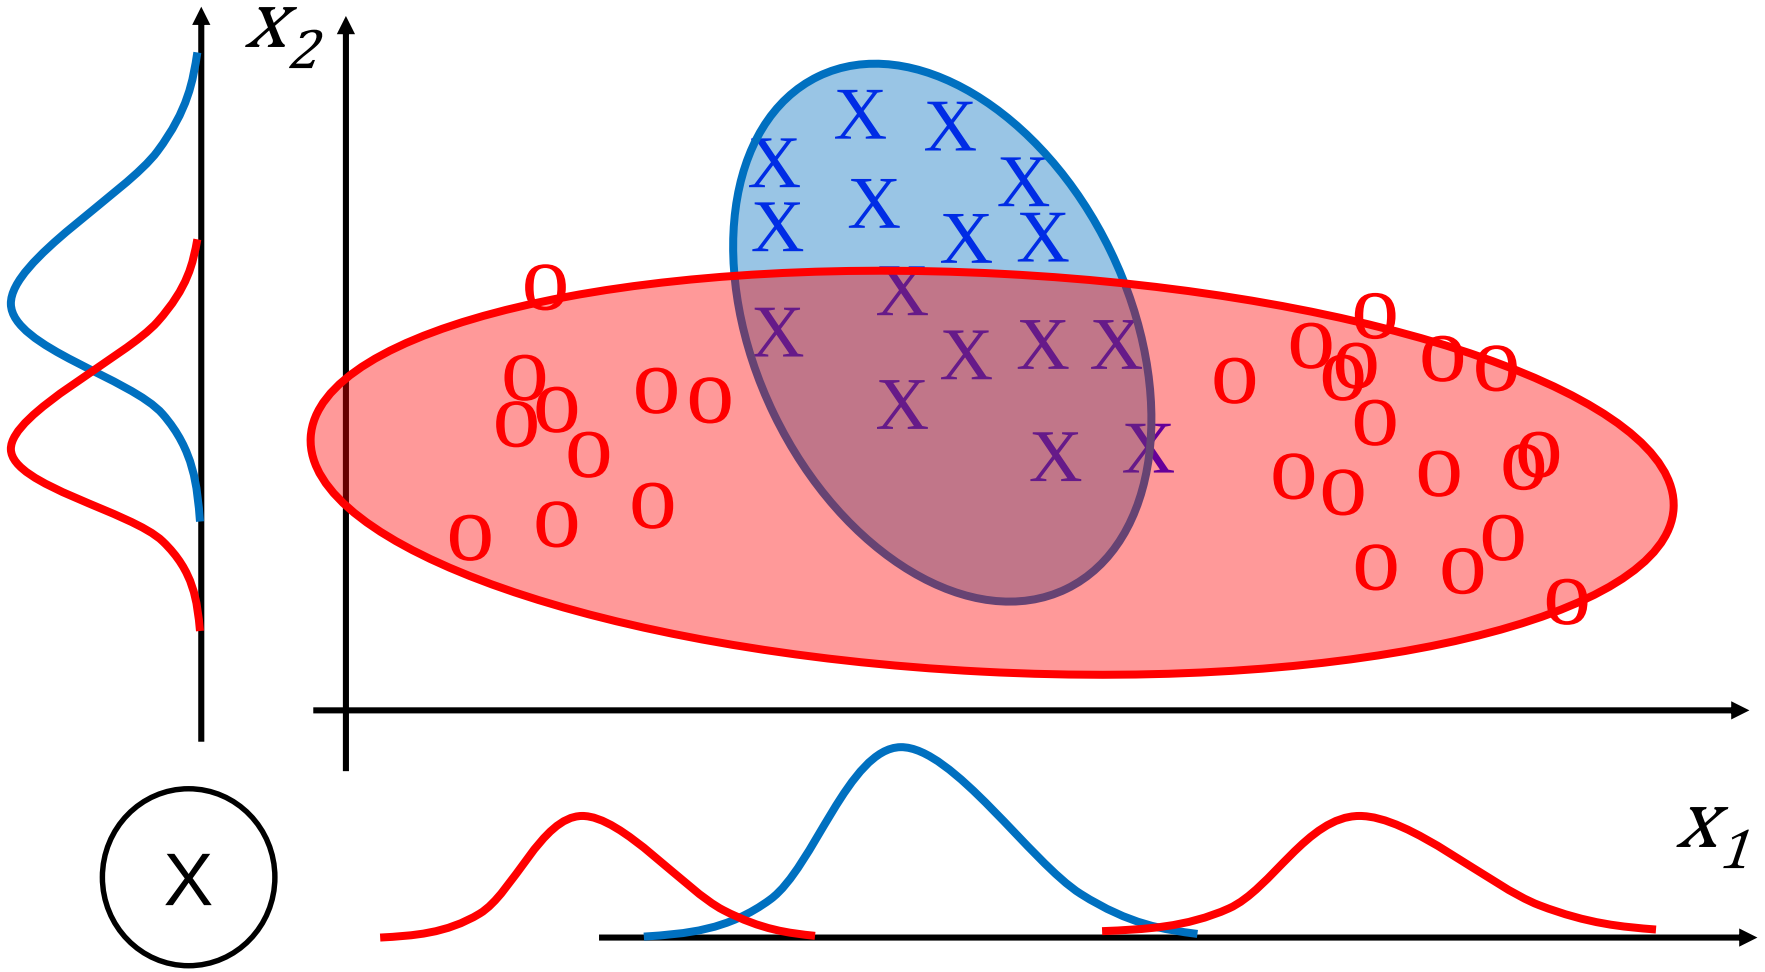
ONERA
THE FRENCH AEROSPACE LAB

Approche bayésienne naïve



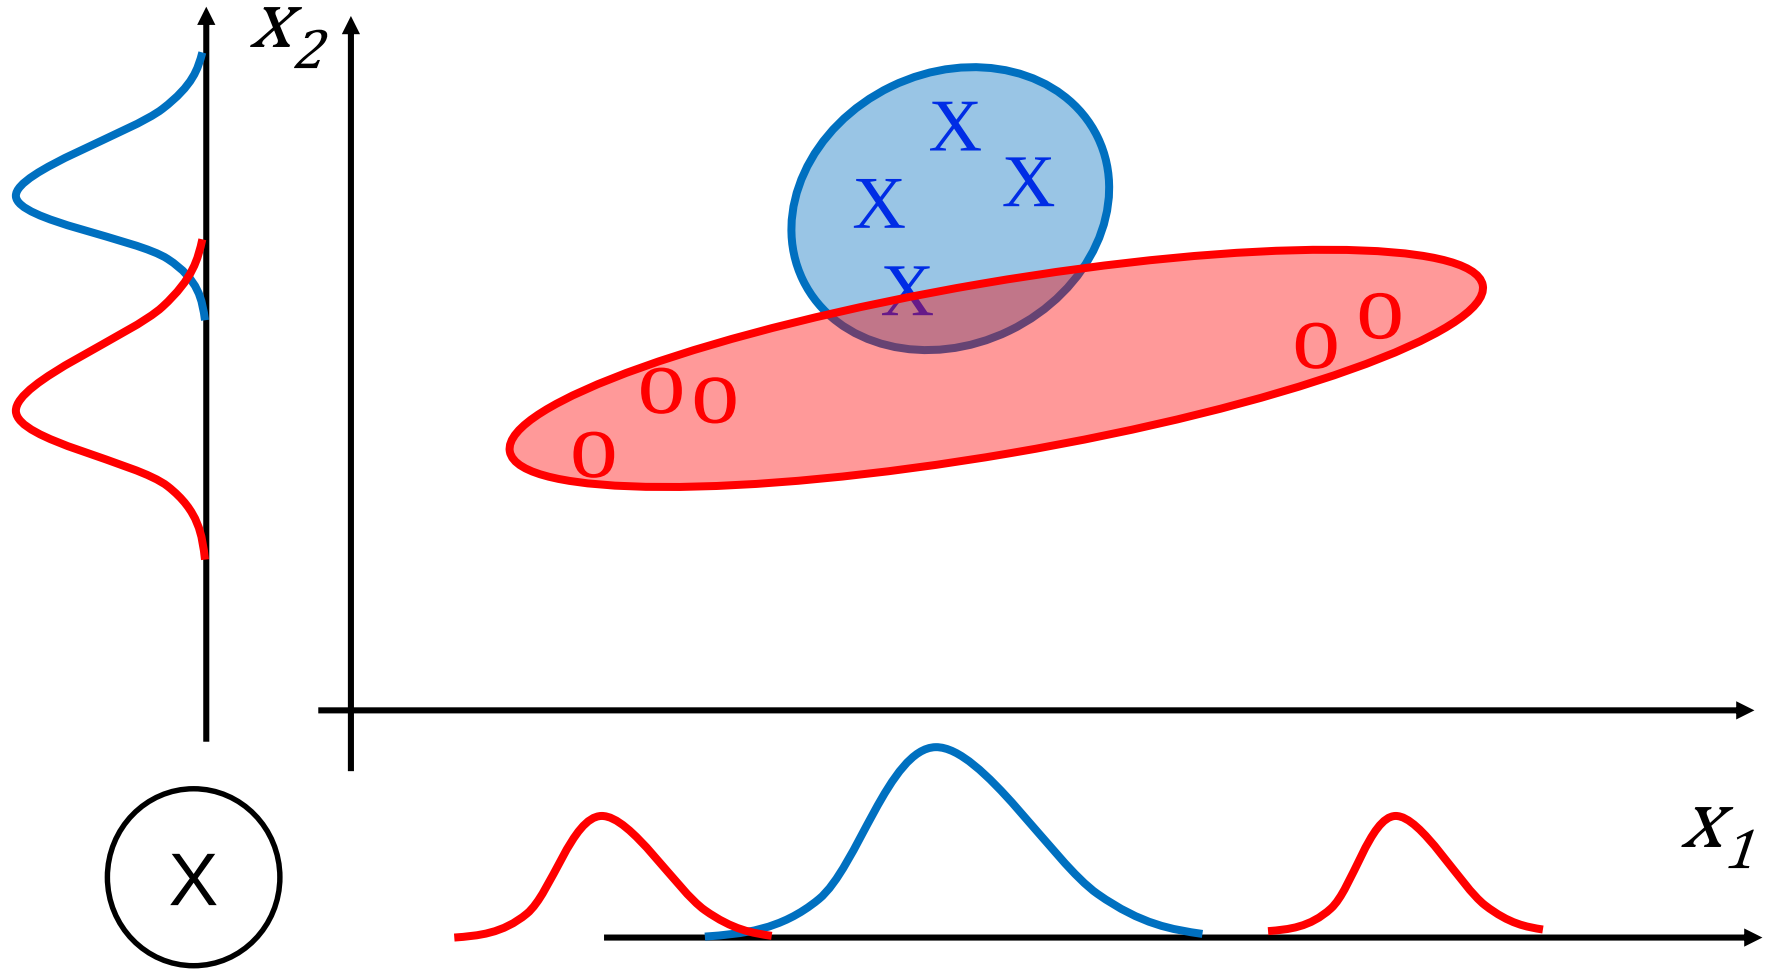
ONERA
THE FRENCH AEROSPACE LAB

Approche bayésienne naïve vs. multivariée



ONERA
THE FRENCH AEROSPACE LAB

Approche bayésienne naïve vs. multivariée



ONERA
THE FRENCH AEROSPACE LAB

Approche bayésienne: résumé

- Théorie probabiliste de la décision → calcul de la loi a posteriori

- Expression de la loi a posteriori:
  - Modèle gaussien multivarié
  - Hypothèse d'indépendance conditionnelle.

- Apprentissage
  - Estimation de lois paramétriques simples
- Prédiction
  - Calcul de log-vraisemblance et max sur hypothèses

- Quand l'utiliser? (limitations)
  - Petits problèmes bien modélisés (gaussien multivarié)
  - Caractéristiques non corrélées (bayésien naïf, mais ça peut aussi marcher si c'est corrélé)

ONERA
THE FRENCH AEROSPACE LAB

Stratégie 2: Décider/prédire directement

1. Construire une « bonne » fonction de prédiction à partir des données

Apprentissage = estimation des paramètres de la fonction de décision

- Une « bonne » fonction de prédiction dépend de l'impact potentiel des erreurs
- Modèle statistique: on peut produire des incertitudes de décision, mais pas échantillonner des données

➔ On parle d'approche « discriminante »

- On peut considérer le problème comme une estimation de la loi a posteriori $P(y|\boldsymbol{x})$.

ONERA
THE FRENCH AEROSPACE LAB

Discrimination linéaire binaire

Un exemple simple d'approches discriminante

Principe

- On cherche à **projeter linéairement sur une droite les données** de telle sorte qu'elles soient séparées au mieux
- Formellement, on définit la décision par un vecteur $\boldsymbol{w}$ et un biais b:

$$F(\boldsymbol{x}) = (\boldsymbol{w}^t.\boldsymbol{x} + b) \underset{2}{\overset{1}{\gtrless}} 0$$

- Le signe de la fonction donne la classe

- Plusieurs stratégies pour définir une « bonne » projection linéaire:
  - moindre carrés
  - régression logistique
  - discrimination de Fisher

ONERA
THE FRENCH AEROSPACE LAB

Moindres carrés

- Première idée: on cherche à prédire directement la classe et on minimise l'erreur quadratique (régression):

$$J(\boldsymbol{w}, b) = \frac{1}{N}\sum_{i}(\boldsymbol{w}^t.\boldsymbol{x}_i + b - y_i)^2$$

- Qui peut se récrire:

$$J(\boldsymbol{W}) = \|\boldsymbol{W}.\boldsymbol{X} - Y\|^2$$

avec $\boldsymbol{W} = [\boldsymbol{w}, b]$ et $X_i = [\boldsymbol{x}_i, 1]$

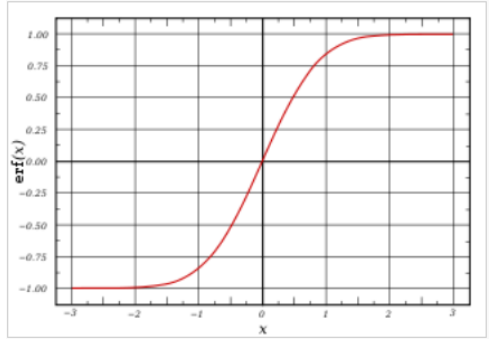
- La solution analytique est celle des moindres carrés:

$$\boldsymbol{W}^* = (\boldsymbol{X}^t.\boldsymbol{X})^{-1}\boldsymbol{X}^t Y$$

- Conceptuellement simple mais:
  - Demande d'inverser une matrice de corrélation: donc très coûteux (en pratique on ne calcule pas les poids comme ça)
  - Très sensible aux données aberrantes (« outliers »)

ONERA
THE FRENCH AEROSPACE LAB

Régression logistique



- Principe: on modélise directement la **loi a posteriori** selon:

$$P(y \mid \mathbf{x}) = \sigma(\mathbf{w}^t \mathbf{x} + b) \qquad \text{où} \quad \sigma(a) = \frac{1}{1+\exp(-a)}$$

- Approximation « lisse » de la fonction créneau
- On cherche les paramètres $\boldsymbol{w}$ et b qui maximisent la log-vraisemblance:

$$J(\mathbf{w}, b) = -\sum_{n=1}^{N} \ln p(y_n \mid z_n)$$

$$= -\sum_{n=1}^{N} y_n \ln z_n + (1-y_n)\ln(1-z_n)$$

si y =1 si y =0

avec

$$z_n = \sigma(\mathbf{w}^t \mathbf{x}_n + b)$$

ONERA
THE FRENCH AEROSPACE LAB

Optimisation de la régression logistique

- La minimisation du critère n'admet pas formulation analytique
- Astuce: Le gradient du critère se calcule facilement

$$\frac{\partial J_n}{\partial \mathbf{w}} = (z_n - y_n)\,\mathbf{x}_n$$

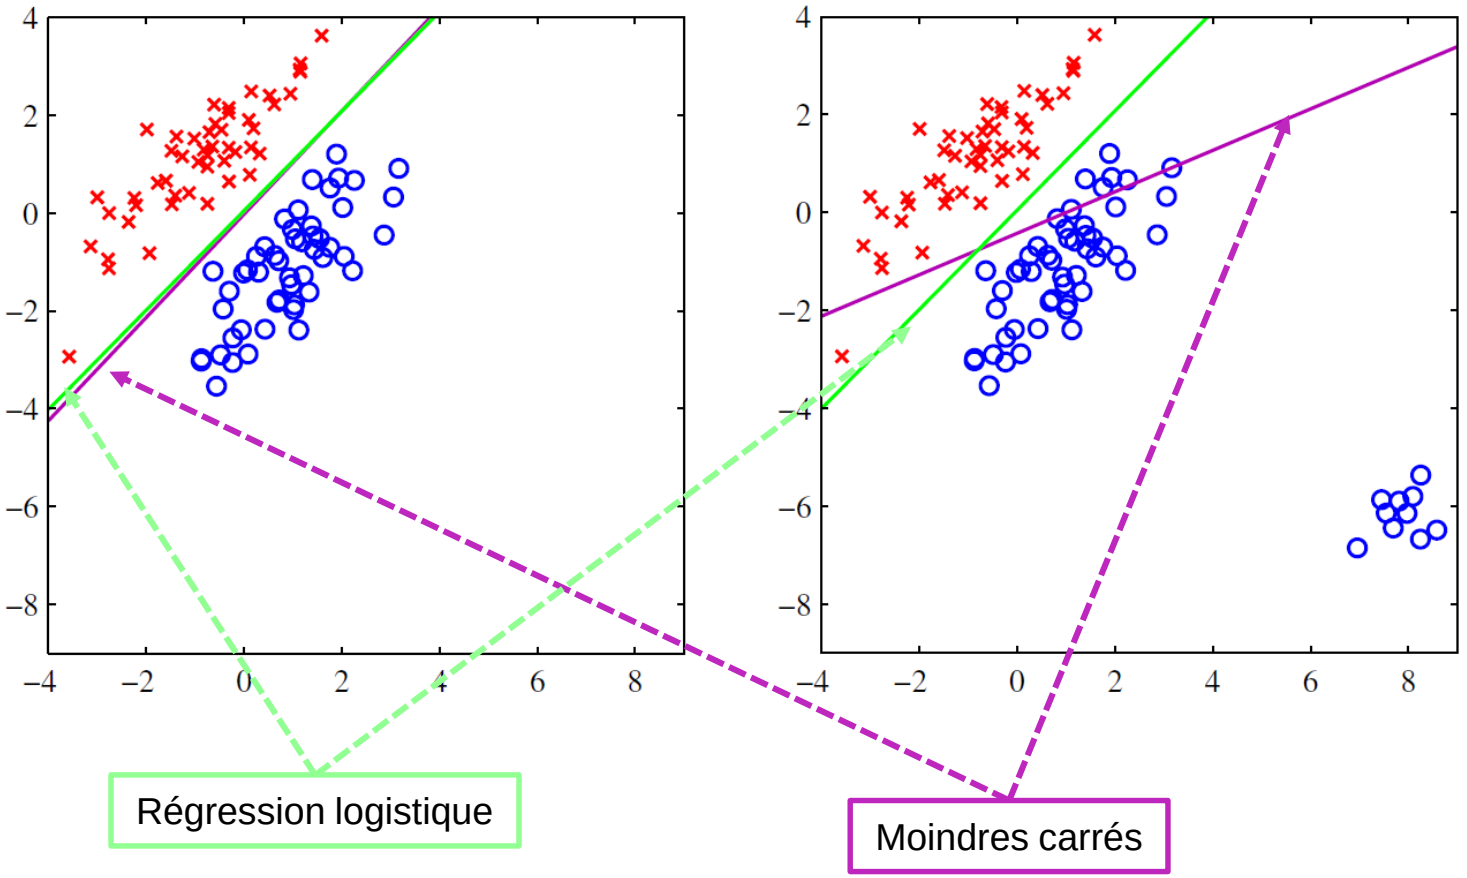
➔ On utilise une descente de gradient pour minimiser.

➔ Il existe une version au second ordre (Newton) conduisant à un algorithme des moindres carrés pondérés.

- La direction de prédiction est moins sensible aux données aberrantes.

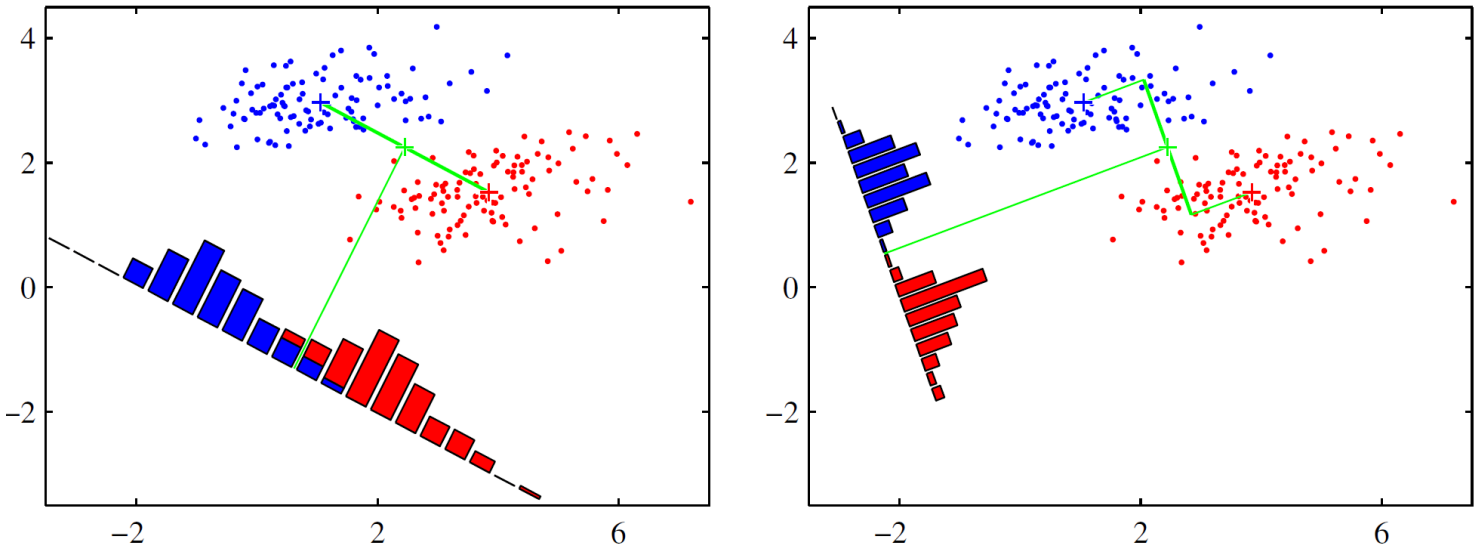
ONERA
THE FRENCH AEROSPACE LAB

Sensibilité aux « *outliers* »



ONERA
THE FRENCH AEROSPACE LAB

Analyse discriminante linéaire (Fisher)



Principe: maximiser le contraste entre deux populations projetées selon le critère de Rayleigh

$$J = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2}$$

Où m_k et s_k sont les moyennes et variances 1-D des deux populations à contraster.

ONERA
THE FRENCH AEROSPACE LAB

Analyse discriminante linéaire (Fisher)

- Lorsque l'on projette selon $\boldsymbol{w}^t.\boldsymbol{x} + b$, le critère s'exprime selon:

$$J(\boldsymbol{w}) = \frac{\boldsymbol{w}^t \boldsymbol{S}_B \boldsymbol{w}}{\boldsymbol{w}^t \boldsymbol{S}_I \boldsymbol{w}}$$

où

$$\boldsymbol{S}_B = (\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)^t.(\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)$$

est la matrice de covariance inter-classe et

$$S_I = \sum_{i \in C_1} (\boldsymbol{x_i} - \boldsymbol{\mu_1})(\boldsymbol{x_i} - \boldsymbol{\mu_1})^t + \sum_{i \in C_2} (\boldsymbol{x_i} - \boldsymbol{\mu_2})(\boldsymbol{x_i} - \boldsymbol{\mu_2})^t$$

est la matrice de covariance intra-classe.

- On peut montrer que la direction qui maximise le contraste est colinéaire à:

$$w^* = \boldsymbol{S}_I^{-1}(\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)$$

C'est aussi le vecteur propre de la plus grande valeur propre de $\boldsymbol{S}_I^{-1}.\boldsymbol{S}_B$.

ONERA
THE FRENCH AEROSPACE LAB

Discrimination linéaire: résumé

- Décision réduite à rechercher une direction de projection
- Plusieurs algorithmes pour apprendre directement la direction:
  - Moindres carrés
  - Régression logistique
  - Discrimination de Fisher
- Quand l'utiliser? (limitations)
  - Petites dimensions
  - Distributions monomodales
- Remarques:
  - On peut retrouver une surface quadratique en augmentant l'espace de représentation par des combinaisons polynomiales (cf. TD)
  - On peut définir des versions « multi-classe »
  - On verra comment mieux contrôler le calcul et la forme d'une surface séparatrice (SVM)

ONERA
THE FRENCH AEROSPACE LAB

A retenir

- « Programmer à partir des données »
  - Deux phases: apprentissage et prédiction
  - Plusieurs variétés de prédicteurs et d'apprentissage
- Démarche générique:
  - Constitution d'une base d'apprentissage
  - Analyse préliminaire des données + préparation
  - Conception du modèle
  - Optimisation
  - Evaluation
- Deux approches élémentaires:
  - Modélisation bayésienne: approche « générative »
  - Analyse discriminante linéaire: approche « discriminante »

ONERA
THE FRENCH AEROSPACE LAB

Références

- R.O. Duda and P.E. Hart, Pattern classification and scene analysis, John Wiley & Sons, New York, 1973.
- P.A. Devijver and J. Kittler, Pattern Recognition, a Statistical Approach, Prentice Hall, Englewood Cliffs, 1982)
- K. Fukunaga, Introduction to Statistical Pattern Recognition (Second Edition), Academic Press, New York, 1990.
- L. Breiman, J.H. Friedman, R.A. Olshen, and C.J. Stone, Classification and regression trees, Wadsworth, 1984.
- S. Haykin, Neural Networks, a Comprehensive Foundation. (Macmillan, New York, NY., 1994)
- L. Devroye, L. Györfi and G. Lugosi, A Probabilistic Theory of Pattern Recognition, (Springer-Verlag 1996)
- V. N. Vapnik, The nature of statistical learning theory (Springer-Verlag, 1995)
- C. Bishop, Pattern Recognition and Machine Learning, (https://www.microsoft.com/en-us/research/uploads/prod/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf).
- Jerome H. Friedman, Robert Tibshirani et Trevor Hastie, The Elements of Statistical Learning: Data Mining, Inference, and Prediction (https://web.stanford.edu/~hastie/ElemStatLearn/).
- G. James, D. Witten, T. Hastie & R.Tibshirani, An Introduction to statistical learning, Springer Texts in Statistics (https://www.statlearning.com/)
- Ian Goodfellow and Yoshua Bengio and Aaron Courville, Deep Learning, An MIT Press book (http://www.deeplearningbook.org)
- B. Scholkopf, A. Smola, Learning with kernels, (MIT Press, 2001)
- Kevin Murphy, Machine Learning: a Probabilistic Perspective, (MIT Press, 2013)
- Hal Daumé III, A Course in Machine Learning (http://ciml.info/)

ONERA
THE FRENCH AEROSPACE LAB

Bases de données

- UCI Repository: http://www.ics.uci.edu/~mlearn/MLRepository.html
- UCI KDD Archive: http://kdd.ics.uci.edu/summary.data.application.html
- Statlib: http://lib.stat.cmu.edu/
- Delve: http://www.cs.utoronto.ca/~delve/
- Kaggle: https://www.kaggle.com/
- Benchmarks (Vision):
  - ImageNet: http://image-net.org/
  - MS COCO: http://cocodataset.org/
  - MNIST et plus: http://rodrigob.github.io/are_we_there_yet/build/classification_datasets_results.html
  - CV on line: https://computervisiononline.com/datasets
  - Kitti: http://www.cvlibs.net/datasets/kitti/
  - Waymo: https://waymo.com/open

Journaux

- Journal of Machine Learning Research www.jmlr.org
- Machine Learning
- Neural Computation
- Neural Networks
- IEEE Transactions on Neural Networks
- IEEE Transactions on Pattern Analysis and Machine Intelligence
- Annals of Statistics
- Journal of the American Statistical Association
- ...

Conférences

- International Conference on Machine Learning (ICML)
- European Conference on Machine Learning (ECML)
- Neural Information Processing Systems (NIPS)
- International Conference on Learning Representations (ICLR)
- Uncertainty in Artificial Intelligence (UAI)
- International Joint Conference on Artificial Intelligence (IJCAI)
- International Conference on Neural Networks (ICNN)
- Conference of the American Association for Artificial Intelligence (AAAI)
- IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- European Conference on Computer Vision (ECCV)
- International Conference on Computer Vision (ICCV)
- IEEE International Conference on Data Mining (ICDM)
- …

Cours & tutoriaux

- Des MOOC (Français et Anglais)
- Des tutoriaux associés aux conférences (orientés recherche)
- Des cours en français:
  - https://gricad-gitlab.univ-grenoble-alpes.fr/talks/fidle
  - https://www.college-de-france.fr/site/stephane-mallat/_course.htm

- Des « cheat sheets »
  - https://stanford.edu/~shervine/teaching/

ONERA
THE FRENCH AEROSPACE LAB

Logiciels

- Environnement génériques: Matlab, ScikitLearn
- Environnements Deep Learning: Tensor Flow, Pytorch, mxnet…
- Beaucoup de codes sur GitHub



Le TD1

- Partie 1: Les approches élémentaires sur une première base
  - Programmation Python
  - Application de la démarche

- Partie 2: Utilisation de la bibliothèque scikit-learn
  - Les approches sur une autre base

ONERA
THE FRENCH AEROSPACE LAB

Utilisation de Colab

- Environnement de développement Python (Notebook « .ipynb »)
- Ressources de calcul distantes (GPU)
- C’est proposé par Google

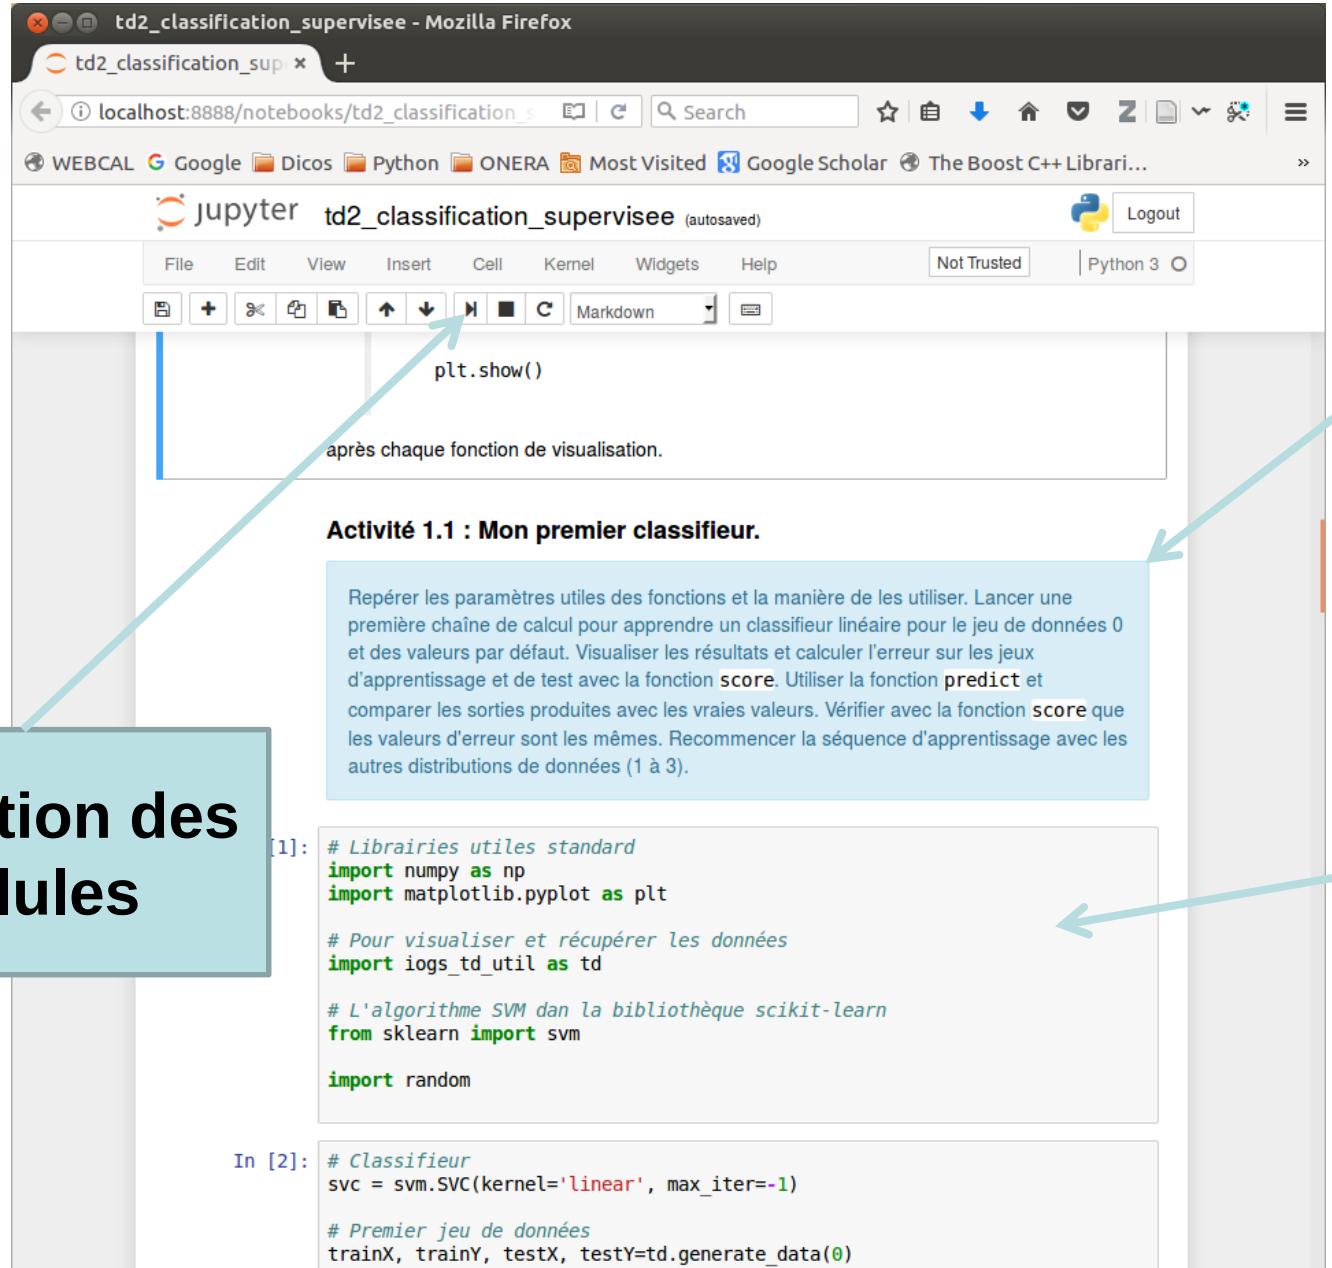
- https://colab.research.google.com/

Etapes

- Se créer un gmail (ou utiliser le votre)
- Se connecter à Colab
- Ouvrir le Notebook du TD (td_gaussien_bayesien.ipynb)
- Modifiez directement le notebook.

ONERA
THE FRENCH AEROSPACE LAB

Utilisation des « Notebook Python »



Exécution des cellules

Texte

Code

ONERA
THE FRENCH AEROSPACE LAB

Pour se mettre à jour sur Python & Numpy

- Intro à Numpy et Matplotlib
  - https://sebastianraschka.com/blog/2020/numpy-intro.html
  - https://cs231n.github.io/python-numpy-tutorial/
- « Cheat sheets »
  - https://www.datacamp.com/community/data-science-cheatsheets

ONERA
THE FRENCH AEROSPACE LAB